

4

Formulación matemática del problema

Este capítulo constituye el núcleo matemático del trabajo. Se formula el modelo de selección de carteras de Markowitz como un problema de optimización cuadrática convexa (QP), se analizan sus condiciones de optimalidad de Karush-Kuhn-Tucker (KKT), se estudia la dualidad y se deriva la solución analítica de la frontera eficiente en el caso sin restricciones de desigualdad. La notación y los resultados aquí desarrollados son la base sobre la que se construye la implementación computacional del Capítulo 7.

4.1 El modelo media-varianza como problema de optimización

4.1.1 Notación

Sea un universo de n activos financieros. Se denota:

- $\mathbf{w} = (w_1, \dots, w_n)^T \in \mathbb{R}^n$: vector de pesos de la cartera.
- $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T \in \mathbb{R}^n$: vector de rentabilidades esperadas, donde $\mu_i = \mathbb{E}[r_i]$.
- $\boldsymbol{\Sigma} = [\sigma_{ij}] \in \mathbb{R}^{n \times n}$: matriz de covarianza, simétrica y semidefinida positiva: $\boldsymbol{\Sigma} \succeq 0$.
- $\mathbf{1} = (1, \dots, 1)^T \in \mathbb{R}^n$.

4.1.2 Formulación primal

El problema de Markowitz en su forma estándar (minimizar riesgo sujeto a una rentabilidad objetivo) se escribe:

$$\begin{aligned}
& \min_{\mathbf{w} \in \mathbb{R}^n} f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} \\
& \text{sujeto a } \mathbf{w}^T \boldsymbol{\mu} \geq \mu^*, \\
& \quad \mathbf{1}^T \mathbf{w} = 1, \\
& \quad w_i \geq 0, \quad i = 1, \dots, n, \\
& \quad w_i \leq w_{\max}, \quad i = 1, \dots, n.
\end{aligned} \tag{4.1}$$

El factor $\frac{1}{2}$ en la función objetivo es puramente algebraico: simplifica las expresiones de las derivadas sin alterar el óptimo. La primera restricción exige que la cartera alcance al menos una rentabilidad esperada μ^* . La segunda es la restricción de presupuesto. Las dos últimas son restricciones de desigualdad que acotan inferior y superiormente cada peso.

El caso particular en que se omite la restricción de rentabilidad objetivo ($\mathbf{w}^T \boldsymbol{\mu} \geq \mu^*$) se conoce como **cartera de mínima varianza global** (GMV):

$$\min_{\mathbf{w}} \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} \quad \text{s.a.} \quad \mathbf{1}^T \mathbf{w} = 1, \quad \mathbf{w} \geq \mathbf{0}, \quad \mathbf{w} \leq w_{\max} \mathbf{1}. \tag{4.2}$$

4.2 Convexidad del problema cuadrático

4.2.1 Definición y propiedades

Un problema de optimización es **convexo** si la función objetivo es convexa y la región factible es un conjunto convexo. La convexidad es una propiedad crucial porque garantiza que cualquier mínimo local es también mínimo global, y que las condiciones KKT son necesarias y suficientes para la optimalidad [Boyd y Vandenberghe, 2004](#).

4.2.2 Convexidad de la función objetivo

La función objetivo es la forma cuadrática:

$$f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w}. \tag{4.3}$$

Su matriz hessiana es $\nabla^2 f(\mathbf{w}) = \Sigma$. Dado que Σ es una matriz de covarianza, es semidefinida positiva por construcción:

$$\mathbf{x}^T \Sigma \mathbf{x} = \text{Var}[\mathbf{x}^T \mathbf{r}] \geq 0, \quad \forall \mathbf{x} \in \mathbb{R}^n. \tag{4.4}$$

Por tanto, f es una función convexa ($\Sigma \geq 0$ implica convexidad; si $\Sigma > 0$, la función es estrictamente convexa). En la práctica, con $T > n$ observaciones y activos no redundantes, Σ es definida positiva y la solución es única.

4.2.3 Convexidad de la región factible

La región factible $\mathcal{F}$ está definida por:

$$\mathcal{F} = \left\{ \mathbf{w} \in \mathbb{R}^n \left| \begin{array}{l} \mathbf{1}^T \mathbf{w} = 1, \\ \mathbf{w}^T \boldsymbol{\mu} \geq \mu^*, \\ 0 \leq w_i \leq w_{\max}, \quad i = 1, \dots, n \end{array} \right. \right\}. \quad (4.5)$$

- La restricción de igualdad $\mathbf{1}^T \mathbf{w} = 1$ define un hiperplano afín, que es un conjunto convexo.
- La restricción $\mathbf{w}^T \boldsymbol{\mu} \geq \mu^*$ define un semiespacio cerrado, también convexo.
- Las restricciones de caja $0 \leq w_i \leq w_{\max}$ definen un hiperrectángulo, intersección de semiespacios, convexo.

$\mathcal{F}$ es la intersección de conjuntos convexos, luego es convexa. Además, es compacta (cerrada y acotada) debido a las restricciones de caja y presupuesto. Como f es continua, el teorema de Weierstrass garantiza la existencia de al menos un mínimo global en $\mathcal{F}$.

Dado que tanto la función objetivo como la región factible son convexas, el problema (4.1) es un **programa cuadrático convexo** (QP). La convexidad garantiza que el óptimo encontrado por cualquier solver estándar (como cvxpy, utilizado en este trabajo) es el óptimo global.

4.3 Restricciones y región factible

4.3.1 Interpretación geométrica

La región factible $\mathcal{F}$ es un politopo convexo en $\mathbb{R}^n$: la intersección del simplex $\Delta_n = \{\mathbf{w} \geq \mathbf{0} \mid \mathbf{1}^T \mathbf{w} = 1\}$ con el hipercubo $[0, w_{\max}]^n$ y el semiespacio $\mathbf{w}^T \boldsymbol{\mu} \geq \mu^*$.

- **Simplex presupuestario:** la restricción $\mathbf{1}^T \mathbf{w} = 1$ con $\mathbf{w} \geq \mathbf{0}$ define el $(n - 1)$ -simplex estándar. Sus n vértices son los vectores canónicos $\mathbf{e}_i$ (invertir todo en un solo activo).
- **Cotas por activo:** la restricción $w_i \leq w_{\max}$ trunca el simplex, eliminando los vértices (carteras concentradas en un único activo). Esto hace la región más realista pero también más compleja: la solución ya no admite una expresión analítica cerrada.
- **Rentabilidad objetivo:** $\mathbf{w}^T \boldsymbol{\mu} \geq \mu^*$ es un semiespacio que corta el simplex. Para μ^* grande, la región factible puede quedar vacía (el problema es infactible).

4.4 Condiciones de Karush-Kuhn-Tucker (KKT)

4.4.1 Planteamiento general

Consideremos el problema de optimización con restricciones de igualdad y desigualdad:

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{s.a.} \quad & g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m, \\ & h_j(\mathbf{x}) = 0, \quad j = 1, \dots, p. \end{aligned} \quad (4.6)$$

El **Lagrangiano** asociado es:

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i g_i(\mathbf{x}) + \sum_{j=1}^p \nu_j h_j(\mathbf{x}), \quad (4.7)$$

donde $\lambda_i \geq 0$ son los multiplicadores de las restricciones de desigualdad y $\nu_j \in \mathbb{R}$ los de las igualdades.

4.4.2 Condiciones KKT para el QP de Markowitz

Escribimos el problema (4.1) en la forma estándar de (4.6). La función objetivo es $f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w}$. Las restricciones de desigualdad se expresan como $g_i(\mathbf{w}) \leq 0$:

$$g_i^{(1)}(\mathbf{w}) = -w_i \leq 0, \quad i = 1, \dots, n, \quad (\text{long-only}), \quad (4.8)$$

$$g_i^{(2)}(\mathbf{w}) = w_i - w_{\max} \leq 0, \quad i = 1, \dots, n, \quad (\text{tope por activo}), \quad (4.9)$$

$$g^{(3)}(\mathbf{w}) = \mu^* - \mathbf{w}^T \boldsymbol{\mu} \leq 0, \quad (\text{rentabilidad objetivo}). \quad (4.10)$$

Y las restricciones de igualdad $h(\mathbf{w}) = 0$:

$$h(\mathbf{w}) = \mathbf{1}^T \mathbf{w} - 1 = 0. \quad (4.11)$$

Introducimos los multiplicadores:

- $\alpha_i \geq 0$ para $g_i^{(1)}$ (cota inferior).
- $\beta_i \geq 0$ para $g_i^{(2)}$ (cota superior).
- $\gamma \geq 0$ para $g^{(3)}$ (rentabilidad objetivo).
- $\lambda \in \mathbb{R}$ para h (presupuesto).

El Lagrangiano es:

$$\begin{aligned} \mathcal{L}(\mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta}, \gamma, \lambda) = & \frac{1}{2} \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w} - \sum_{i=1}^n \alpha_i w_i + \sum_{i=1}^n \beta_i (w_i - w_{\max}) \\ & + \gamma (\mu^* - \mathbf{w}^T \boldsymbol{\mu}) + \lambda (1 - \mathbf{1}^T \mathbf{w}). \end{aligned} \quad (4.12)$$

Las **condiciones KKT** para el óptimo $\mathbf{w}^*$ son:

1. Estacionariedad

El gradiente del Lagrangiano respecto a $\mathbf{w}$ se anula en el óptimo:

$$\nabla_{\mathbf{w}} \mathcal{L} = \Sigma \mathbf{w}^* - \alpha + \beta - \gamma \mu - \lambda \mathbf{1} = \mathbf{0}. \quad (4.13)$$

Esta ecuación tiene una interpretación financiera directa: en el óptimo, el coste marginal de aumentar el peso de cualquier activo (en términos de riesgo adicional, $[\Sigma \mathbf{w}^*]_i$) se equilibra exactamente con el beneficio marginal (en términos de retorno, $\gamma \mu_i$) ajustado por los multiplicadores de las restricciones activas y el coste de presupuesto λ .

2. Factibilidad primal

El punto $\mathbf{w}^*$ debe satisfacer todas las restricciones:

$$\mathbf{1}^T \mathbf{w}^* = 1, \quad 0 \leq w_i^* \leq w_{\max}, \quad \mathbf{w}^{*T} \mu \geq \mu^*. \quad (4.14)$$

3. Factibilidad dual

Los multiplicadores de las restricciones de desigualdad deben ser no negativos:

$$\alpha_i \geq 0, \quad \beta_i \geq 0, \quad \gamma \geq 0. \quad (4.15)$$

4. Holgura complementaria

Para cada restricción de desigualdad, o bien la restricción está activa (se cumple con igualdad) o bien su multiplicador es cero:

$$\alpha_i w_i^* = 0, \quad i = 1, \dots, n, \quad (4.16)$$

$$\beta_i (w_i^* - w_{\max}) = 0, \quad i = 1, \dots, n, \quad (4.17)$$

$$\gamma (\mu^* - \mathbf{w}^{*T} \mu) = 0. \quad (4.18)$$

La holgura complementaria tiene una interpretación económica clara:

- Si un activo tiene peso positivo pero inferior al tope ($0 < w_i^* < w_{\max}$), entonces $\alpha_i = \beta_i = 0$, y la condición de estacionariedad se reduce a $[\Sigma \mathbf{w}^*]_i - \gamma \mu_i - \lambda = 0$: el coste marginal de riesgo iguala exactamente al beneficio marginal de rentabilidad ajustado por el presupuesto.
- Si $w_i^* = 0$, entonces $\alpha_i \geq 0$ y $\beta_i = 0$: el activo está fuera de la cartera porque su contribución al riesgo supera su contribución a la rentabilidad.
- Si $w_i^* = w_{\max}$, entonces $\alpha_i = 0$ y $\beta_i \geq 0$: el activo está en su tope porque su rentabilidad justifica asumir más riesgo del que permiten las restricciones.

4.4.3 Verificación numérica de las KKT

En nuestra implementación, verificamos explícitamente que la solución numérica proporcionada por `cvxpy` satisface las condiciones KKT (ver `test test_condiciones_kkt` en `tests/test_optimization.py`). Para ello, se calculan los multiplicadores λ , α , β y γ a partir de la solución numérica y se comprueba que se satisfacen todas las condiciones con una tolerancia de 10^{-4} . Este test constituye una validación independiente de la corrección del solver.

4.5 Dualidad e interpretación económica

4.5.1 El problema dual

Asociado al problema primal (4.1) existe un **problema dual** que proporciona una cota inferior del valor óptimo primal. En optimización convexa que satisface las condiciones de Slater (existencia de un punto estrictamente factible), la **dualidad fuerte** garantiza que los valores óptimos primal y dual coinciden [Boyd y Vandenberghe, 2004](#).

Para nuestro QP, la condición de Slater se satisface siempre que exista al menos un punto estrictamente interior a la región factible, lo cual ocurre si μ^* es menor que la máxima rentabilidad individual y $n \cdot w_{\max} > 1$ (condición necesaria para que la restricción de presupuesto sea compatible con los topes).

4.5.2 Interpretación de los multiplicadores

Los multiplicadores de KKT tienen una interpretación económica como **precios sombra**:

- λ es el precio sombra de la restricción presupuestaria: mide cuánto aumentaría la varianza mínima si se relajara la restricción de presupuesto en una unidad (es decir, si se permitiera invertir un euro adicional).
- γ es el precio sombra de la rentabilidad objetivo: mide la reducción de varianza que se obtendría al relajar la exigencia de rentabilidad en una unidad.
- α_i es el coste marginal de la restricción de no negatividad para el activo i : si $\alpha_i > 0$, eliminar la restricción $w_i \geq 0$ permitiría tomar una posición corta en i y reducir la varianza de la cartera.
- β_i es el coste marginal del tope superior: si $\beta_i > 0$, relajar $w_i \leq w_{\max}$ permitiría invertir más en i y reducir la varianza.

4.6 Solución analítica de la frontera eficiente

4.6.1 Caso sin restricciones de desigualdad

Cuando se eliminan las restricciones de desigualdad ($w_i \geq 0$ y $w_i \leq w_{\max}$), el problema admite una solución analítica cerrada que constituye uno de los resultados clásicos de la teoría de carteras [Merton, 1972](#). En toda esta sección suponemos que Σ es **definida positiva** ($\Sigma > 0$), hipótesis bajo la cual Σ^{-1} existe; en la práctica se cumple cuando el número de observaciones supera al de activos y ninguna combinación de activos es redundante (cuestión que se discute en el Capítulo 5).

El problema se reduce a:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} \\ \text{s.a.} \quad & \mathbf{1}^T \mathbf{w} = 1, \\ & \mathbf{w}^T \boldsymbol{\mu} = \mu_p. \end{aligned} \quad (4.19)$$

Nótese que la restricción de rentabilidad se ha escrito como igualdad (=) en lugar de desigualdad ($\geq$): en el óptimo, cualquier target μ_p alcanzable se saturará porque añadir rentabilidad sin aumentar riesgo es siempre beneficioso.

4.6.2 Derivación mediante multiplicadores de Lagrange

El Lagrangiano del problema (4.19) es:

$$\mathcal{L}(\mathbf{w}, \lambda, \gamma) = \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} + \lambda(1 - \mathbf{1}^T \mathbf{w}) + \gamma(\mu_p - \mathbf{w}^T \boldsymbol{\mu}). \quad (4.20)$$

La condición de estacionariedad $\nabla_{\mathbf{w}} \mathcal{L} = \mathbf{0}$ proporciona:

$$\Sigma \mathbf{w} - \lambda \mathbf{1} - \gamma \boldsymbol{\mu} = \mathbf{0} \implies \mathbf{w} = \Sigma^{-1}(\lambda \mathbf{1} + \gamma \boldsymbol{\mu}). \quad (4.21)$$

Sustituyendo en las restricciones $\mathbf{1}^T \mathbf{w} = 1$ y $\boldsymbol{\mu}^T \mathbf{w} = \mu_p$, se obtiene un sistema lineal 2×2 para (λ, γ) :

$$\begin{pmatrix} A & B \\ B & C \end{pmatrix} \begin{pmatrix} \lambda \\ \gamma \end{pmatrix} = \begin{pmatrix} 1 \\ \mu_p \end{pmatrix}, \quad (4.22)$$

donde se han definido las constantes escalares:

$$A = \mathbf{1}^T \Sigma^{-1} \mathbf{1}, \quad B = \mathbf{1}^T \Sigma^{-1} \boldsymbol{\mu}, \quad C = \boldsymbol{\mu}^T \Sigma^{-1} \boldsymbol{\mu}. \quad (4.23)$$

Estas tres constantes dependen exclusivamente de Σ y $\boldsymbol{\mu}$; no dependen del target μ_p . Como $\Sigma > 0$, también $\Sigma^{-1} > 0$, de modo que $\langle \mathbf{x}, \mathbf{y} \rangle := \mathbf{x}^T \Sigma^{-1} \mathbf{y}$ define un producto interior. En esta métrica $A = \langle \mathbf{1}, \mathbf{1} \rangle$, $C = \langle \boldsymbol{\mu}, \boldsymbol{\mu} \rangle$ y $B = \langle \mathbf{1}, \boldsymbol{\mu} \rangle$, por lo que la desigualdad de Cauchy-Schwarz da $B^2 \leq AC$, con igualdad si y solo si $\boldsymbol{\mu}$ y $\mathbf{1}$ son linealmente dependientes (es decir, todos los activos tienen la misma rentabilidad esperada). Bajo la hipótesis de que $\boldsymbol{\mu}$ y $\mathbf{1}$ son linealmente independientes, se tiene $\Delta = AC - B^2 >$

0, lo que garantiza que la matriz del sistema (4.22) es invertible.

Resolviendo el sistema:

$$\lambda = \frac{C - B\mu_p}{\Delta}, \quad \gamma = \frac{A\mu_p - B}{\Delta}. \quad (4.24)$$

4.6.3 Ecuación de la frontera eficiente

Sustituyendo λ y γ en la expresión de la varianza $\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w}$, se obtiene la ecuación de la frontera eficiente en el espacio (σ_p, μ_p) :

$$\sigma_p^2 = \frac{A\mu_p^2 - 2B\mu_p + C}{\Delta}. \quad (4.25)$$

Esta ecuación describe una **hipérbola** en el plano (σ_p, μ_p) —o una parábola en el plano (σ_p^2, μ_p) —, cuya rama derecha ($\sigma_p \geq 0$) es la **frontera de mínima varianza**: el lugar geométrico de las carteras de menor riesgo para cada nivel de rentabilidad. Su asíntota superior tiene pendiente $\sqrt{\Delta/A}$. La **frontera eficiente** propiamente dicha es solo la mitad superior de esa rama, $\mu_p \geq \mu_{\text{GMV}} = B/A$ (el vértice que se deduce en la ecuación 4.26): por debajo del vértice, toda cartera está dominada por otra de igual riesgo y mayor rentabilidad, y por tanto no es eficiente.

4.6.4 Cartera de mínima varianza global (GMV)

El vértice de la hipérbola corresponde a la cartera de mínima varianza global. Derivando (4.25) respecto a μ_p e igualando a cero:

$$\frac{d\sigma_p^2}{d\mu_p} = \frac{2A\mu_p - 2B}{\Delta} = 0 \implies \boxed{\mu_{\text{GMV}} = \frac{B}{A}}. \quad (4.26)$$

Sustituyendo en (4.24) se obtiene $\lambda = 1/A$, $\gamma = 0$, y el vector de pesos de la GMV es:

$$\mathbf{w}_{\text{GMV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}. \quad (4.27)$$

La varianza de la GMV es $\sigma_{\text{GMV}}^2 = 1/A$.

4.6.5 Cartera de máximo ratio de Sharpe

La cartera tangente (máximo ratio de Sharpe) se obtiene maximizando $S_p = (\mu_p - r_f)/\sigma_p$ sobre la frontera. Con $r_f = 0$, la condición de optimalidad es:

$$\frac{\mu_p}{\sigma_p} = \frac{d\mu_p}{d\sigma_p} \implies \boxed{\mu_T = \frac{C}{B}, \quad \sigma_T^2 = \frac{C}{B^2}}. \quad (4.28)$$

Y los pesos correspondientes:

$$\mathbf{w}_T = \frac{\mathbf{\Sigma}^{-1} \boldsymbol{\mu}}{\mathbf{1}^T \mathbf{\Sigma}^{-1} \boldsymbol{\mu}}. \quad (4.29)$$

4.6.6 Validación con la implementación numérica

La solución analítica (4.27) proporciona una referencia exacta contra la que verificar la implementación numérica con `cvxpy`. En el test `test_gmv_coincide_con_analitica` de nuestro código, generamos una matriz $\mathbf{\Sigma}$ sintética (de 3×3), resolvemos el QP sin restricciones de desigualdad y comprobamos que la solución numérica coincide con la expresión (4.27) con un error relativo inferior a 10^{-5} . Este acuerdo valida tanto la formulación del QP como su resolución numérica.

4.7 Del caso analítico al caso con restricciones

Cuando se añaden las restricciones $w_i \geq 0$ y $w_i \leq w_{\max}$, la solución deja de admitir una expresión cerrada. La frontera eficiente ya no es una hipérbola perfecta, sino una curva suave definida a trozos por los puntos donde las restricciones se activan o desactivan. La resolución debe ser necesariamente numérica.

Sin embargo, las propiedades cualitativas se conservan:

- El problema sigue siendo convexo (la región factible es un subconjunto convexo del simplex).
- La solución es única si $\mathbf{\Sigma} > 0$.
- Las condiciones KKT siguen caracterizando completamente el óptimo.
- La frontera eficiente es creciente y cóncava en el espacio (σ_p, μ_p) .

Esto justifica el uso de `cvxpy` como solver exacto: la convexidad garantiza optimalidad global, y las condiciones KKT proporcionan una herramienta de verificación independiente del solver.

Bibliografía

Areia, José (dic. de 2023). *Polytechnic University of Leiria: LaTeX Thesis Template*. URL: <https://github.com/joseareia/ipleiria-thesis>.

Best, Michael J. y Robert R. Grauer (1991). «On the sensitivity of mean-variance-efficient portfolios to changes in asset means: some analytical and computational results». En: *The Review of Financial Studies* 4.2, págs. 315-342.

Black, Fischer y Robert Litterman (1992). «Global portfolio optimization». En: *Financial Analysts Journal* 48.5, págs. 28-43.

Boyd, Stephen y Lieven Vandenberghe (2004). *Convex Optimization*. Cambridge University Press.

Breiman, Leo (2001). «Random Forests». En: *Machine Learning* 45.1, págs. 5-32.

Cont, Rama (2001). «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues». En: *Quantitative Finance* 1.2, págs. 223-236.

DeMiguel, Victor, Lorenzo Garlappi y Raman Uppal (2009). «Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy?» En: *The Review of Financial Studies* 22.5, págs. 1915-1953.

Fama, Eugene F. y Kenneth R. French (1993). «Common risk factors in the returns on stocks and bonds». En: *Journal of Financial Economics* 33.1, págs. 3-56.

Gu, Shihao, Bryan Kelly y Dacheng Xiu (2020). «Empirical Asset Pricing via Machine Learning». En: *The Review of Financial Studies* 33.5, págs. 2223-2273.

Jegadeesh, Narasimhan y Sheridan Titman (1993). «Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency». En: *The Journal of Finance* 48.1, págs. 65-91.

Jorion, Philippe (1986). «Bayes-Stein estimation for portfolio analysis». En: *Journal of Financial and Quantitative Analysis* 21.3, págs. 279-292.

Ledoit, Olivier y Michael Wolf (2004). «A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices». En: *Journal of Multivariate Analysis* 88.2, págs. 365-411.

- Lintner, John (1965). «The Valuation of Risk Assets and the Selection of Risky Investments in Stock Portfolios and Capital Budgets». En: *The Review of Economics and Statistics* 47.1, págs. 13-37.
- Markowitz, Harry (1952). «Portfolio Selection». En: *The Journal of Finance* 7.1, págs. 77-91.
- Memmel, Christoph (2003). «Performance hypothesis testing with the Sharpe ratio». En: *Finance Letters* 1.1, págs. 21-23.
- Merton, Robert C. (1972). «An Analytic Derivation of the Efficient Portfolio Frontier». En: *The Journal of Financial and Quantitative Analysis* 7.4, págs. 1851-1872.
- Merton, Robert C. (1980). «On Estimating the Expected Return on the Market: An Exploratory Investigation». En: *Journal of Financial Economics* 8.4, págs. 323-361.
- Michaud, Richard O. (1989). «The Markowitz optimization enigma: is .°ptimized.°ptimal?». En: *Financial Analysts Journal* 45.1, págs. 31-42.
- Ross, Stephen A. (1976). «The Arbitrage Theory of Capital Asset Pricing». En: *Journal of Economic Theory* 13.3, págs. 341-360.
- Sharpe, William F. (1964). «Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk». En: *The Journal of Finance* 19.3, págs. 425-442.
- Sharpe, William F. (1966). «Mutual Fund Performance». En: *The Journal of Business* 39.1, págs. 119-138.
- Tobin, James (1958). «Liquidity Preference as Behavior Towards Risk». En: *The Review of Economic Studies* 25.2, págs. 65-86.
- Zou, Hui y Trevor Hastie (2005). «Regularization and Variable Selection via the Elastic Net». En: *Journal of the Royal Statistical Society: Series B* 67.2, págs. 301-320.

Apéndice

