

1

Introducción

1.1 Motivación y contexto

La gestión cuantitativa de inversiones ha experimentado una transformación profunda en las últimas décadas. El modelo de selección de carteras propuesto por Harry Markowitz en 1952 sentó las bases matemáticas para la diversificación óptima, estableciendo un marco riguroso para el equilibrio entre rentabilidad y riesgo. Sin embargo, la implementación práctica de este modelo se enfrenta a un obstáculo fundamental: la estimación de los parámetros de entrada, especialmente las rentabilidades esperadas de los activos.

1.2 Planteamiento del problema

El modelo de Markowitz requiere como entradas el vector de rentabilidades esperadas μ y la matriz de covarianza Σ . Mientras que Σ puede estimarse con relativa estabilidad a partir de datos históricos —y mejorarse mediante técnicas de shrinkage—, la estimación de μ es notoriamente difícil. Pequeños errores en la predicción de rentabilidades producen carteras muy distintas y, a menudo, peores que una asignación ingenua equiponderada [DeMiguel et al., 2009](#).

Este trabajo explora si las técnicas de Machine Learning pueden mejorar la predicción de μ y, en consecuencia, el rendimiento *out-of-sample* (fuera de la muestra de estimación) de las carteras optimizadas.

1.3 Objetivos

1.3.1 Objetivo general

Diseñar y evaluar un modelo de optimización de carteras que integre la teoría clásica de Markowitz con técnicas de Machine Learning para la predicción de rentabilidades esperadas.

1.3.2 Objetivos específicos

1. Formular el modelo media-varianza como un problema cuadrático convexo (QP) y resolverlo de forma exacta mediante `cvxpy`.
2. Implementar y comparar tres estimadores de la matriz de covarianza: muestral, shrinkage de Ledoit-Wolf y basado en PCA/factores.
3. Desarrollar modelos de Machine Learning (Ridge, Lasso, Random Forest) para predecir las rentabilidades esperadas de cada activo.
4. Evaluar el rendimiento out-of-sample de las carteras mediante backtesting walk-forward, comparándolas contra baselines relevantes.

1.4 Estructura del documento

El resto del documento se organiza como sigue. El Capítulo 2 revisa el estado del arte en optimización de carteras, desde la teoría moderna hasta el aprendizaje automático. El Capítulo 3 presenta el marco teórico financiero. El Capítulo 4 desarrolla la formulación matemática del problema como QP convexo, incluyendo las condiciones KKT y la solución analítica de la frontera eficiente. El Capítulo 5 aborda las limitaciones del modelo clásico y presenta los estimadores robustos de covarianza. El Capítulo 6 describe la aplicación de Machine Learning a la predicción de rentabilidades. El Capítulo 7 detalla la metodología experimental. El Capítulo 8 presenta y discute los resultados. Finalmente, el Capítulo 9 recoge las conclusiones y posibles líneas futuras de investigación.

2

Estado del arte

La optimización de carteras es uno de los problemas más estudiados de las finanzas cuantitativas. Desde su formulación original a mediados del siglo XX, la disciplina ha evolucionado en torno a una tensión persistente: la elegancia del modelo teórico frente a la fragilidad de su aplicación práctica, dominada por el error con que se estiman sus parámetros. Este capítulo revisa esa evolución —de la teoría moderna de carteras a la irrupción del aprendizaje automático— con el doble objetivo de situar las aportaciones más relevantes de la literatura y de delimitar el espacio que ocupa este trabajo.

2.1 De la teoría moderna de carteras al CAPM y la APT

El punto de partida es el trabajo seminal de [Markowitz \(1952\)](#), que formalizó la selección de carteras como un compromiso entre la rentabilidad esperada y el riesgo, medido este último por la varianza. Su principal aportación conceptual fue demostrar que el riesgo de una cartera no es la suma de los riesgos individuales, sino que depende crucialmente de las covarianzas entre activos: la diversificación permite reducir el riesgo sin sacrificar rentabilidad esperada. Este marco media-varianza constituye todavía hoy el lenguaje básico de la gestión cuantitativa.

Poco después, [Tobin \(1958\)](#) introdujo el *teorema de separación*: al incorporar un activo libre de riesgo, la decisión de inversión se descompone en dos etapas independientes —la elección de una única cartera óptima de activos con riesgo (la cartera tangente) y su combinación con el activo seguro—. Esta idea pavimentó el camino hacia los modelos de equilibrio. El *Capital Asset Pricing Model* (CAPM), desarrollado de forma independiente por [Sharpe \(1964\)](#) y [Lintner \(1965\)](#), postuló que, en equilibrio, la rentabilidad esperada de un activo es una función lineal de su riesgo sistemático (la beta respecto al mercado). Como alternativa más general, [Ross \(1976\)](#) propuso la *Arbitrage Pricing Theory* (APT), que explica las rentabilidades mediante varios factores de riesgo sistemáticos en lugar de uno solo, sin apoyarse en los supuestos de equilibrio del CAPM.

En el plano matemático, [Merton \(1972\)](#) obtuvo la solución analítica cerrada de la frontera eficiente en ausencia de restricciones de desigualdad, mostrando que el conjunto de carteras de mínima varianza describe una hipérbola en el plano riesgo-rentabilidad. Este resultado, que se retoma con detalle en el Capítulo 4, es la base sobre la que se construye toda la maquinaria de optimización del presente trabajo.

2.2 El problema del error de estimación

La elegancia del modelo de Markowitz contrasta con su comportamiento práctico. El modelo requiere como entradas el vector de rentabilidades esperadas y la matriz de covarianzas, parámetros que en la práctica no se conocen y deben estimarse a partir de datos históricos. [Merton \(1980\)](#) fue uno de los primeros en señalar que estimar la rentabilidad esperada es mucho más difícil que estimar las varianzas y covarianzas: mientras que la precisión de estas últimas mejora al aumentar la frecuencia de muestreo, la de las primeras solo mejora ampliando el horizonte temporal, lo que exige series de datos inviablemente largas.

Las consecuencias de este hecho son severas. [Best y Grauer \(1991\)](#) demostraron analíticamente que las carteras eficientes son extremadamente sensibles a pequeñas variaciones en las rentabilidades esperadas estimadas: cambios mínimos en las medias producen reasignaciones drásticas de los pesos. En la misma línea, [Michaud \(1989\)](#) acuñó la célebre expresión de que la optimización media-varianza actúa como un «*maximizador del error de estimación*», ya que tiende a asignar pesos desproporcionados precisamente a aquellos activos cuya rentabilidad ha sido sobrestimada por azar; de ahí que las carteras “optimizadas” a menudo rindan peor, fuera de muestra, que alternativas ingenuas.

La evidencia empírica más influyente en este sentido es la de [DeMiguel et al. \(2009\)](#), quienes compararon catorce modelos de optimización frente a la sencilla regla de diversificación ingenua $1/N$ (repartir el capital por igual entre todos los activos). Su conclusión fue contundente: ninguna de las estrategias optimizadas superaba consistentemente a la $1/N$ fuera de muestra, y estimaron que se necesitarían ventanas de estimación de miles de meses para que la ventaja teórica de la optimización compensara el error de estimación. Este resultado es el referente directo frente al que se contrastan los hallazgos del presente trabajo.

2.3 Mejoras en la estimación de la matriz de covarianza

Aunque la covarianza es más fácil de estimar que la rentabilidad esperada, también sufre cuando el número de activos es comparable al de observaciones: la matriz de covarianza muestral se vuelve mal condicionada y produce carteras inestables. Una de las soluciones más exitosas es el *shrinkage* de [Ledoit y Wolf \(2004\)](#), que estima la covarianza como una combinación convexa, de intensidad óptima, entre la matriz muestral y un objetivo bien condicionado (la matriz identidad escalada). El

estimador resultante está mejor condicionado, reduce el error cuadrático medio y da lugar a carteras más estables y diversificadas.

Una vía complementaria es la imposición de una estructura de factores. [Fama y French \(1993\)](#) mostraron que un reducido número de factores comunes —el mercado, el tamaño y el valor— explica buena parte de la variación conjunta de las rentabilidades de las acciones. Modelar la covarianza a través de pocos factores reduce drásticamente el número de parámetros a estimar y filtra el ruido idiosincrásico; esta idea enlaza con la APT de [Ross \(1976\)](#) y con la descomposición en componentes principales que se emplea en este trabajo como tercer estimador de la covarianza (Capítulo 5).

2.4 Enfoques bayesianos e incorporación de visiones

Una familia distinta de soluciones aborda directamente el error en las rentabilidades esperadas mediante la inferencia bayesiana. [Jorion \(1986\)](#) aplicó el estimador de Bayes-Stein, que contrae las rentabilidades esperadas individuales hacia un valor común (típicamente el de la cartera de mínima varianza), reduciendo la varianza del estimador y mejorando el rendimiento fuera de muestra. El enfoque más conocido en la práctica profesional es, no obstante, el modelo de [Black y Litterman \(1992\)](#), que parte de las rentabilidades implícitas en el equilibrio de mercado y las combina, en un marco bayesiano, con las “visiones” subjetivas del inversor. El resultado son carteras más estables e intuitivas que las que produce la optimización media-varianza directa, lo que mitiga el problema de las asignaciones extremas. Estos enfoques son conceptualmente afines a la sustitución del estimador ingenuo de la rentabilidad esperada por una predicción mejor informada, que es precisamente lo que en este trabajo se aborda mediante el aprendizaje automático.

2.5 Predicción de rentabilidades y aprendizaje automático

La pregunta de fondo —¿es posible predecir las rentabilidades?— tiene una respuesta matizada. Por un lado, la literatura ha documentado anomalías empíricas explotables, como el efecto *momentum* de [Jegadeesh y Titman \(1993\)](#), según el cual los activos que han obtenido buenas rentabilidades en el pasado reciente tienden a seguir haciéndolo a corto plazo. Por otro, [Cont \(2001\)](#) sistematizó los *hechos estilizados* de las series financieras —colas pesadas, ausencia de autocorrelación lineal en los rendimientos y agrupamiento de la volatilidad—, que limitan severamente la predictibilidad de la rentabilidad y advierten contra los supuestos de normalidad.

En la última década, el aprendizaje automático ha irrumpido con fuerza en este terreno. El estudio de referencia es el de [Gu et al. \(2020\)](#), que evaluó de forma sistemática un amplio catálogo de métodos —desde regresiones penalizadas hasta árboles y redes neuronales— para la predicción de rentabilidades en un gran panel de acciones. Sus conclusiones son especialmente relevantes para este traba-

jo: los métodos no lineales pueden capturar interacciones que los lineales ignoran, pero las ganancias predictivas son modestas (con R^2 fuera de muestra muy pequeños), y la regularización resulta decisiva para evitar el sobreajuste en un entorno de baja señal-ruido. Entre los métodos concretos, este trabajo emplea los *Random Forests* de Breiman (2001) —un modelo no lineal robusto basado en el promediado de árboles— y dos regresiones regularizadas: el *Ridge* y el *Lasso*. Este último, emparejado con la *elastic net* de Zou y Hastie (2005), realiza además selección automática de variables, lo que resulta especialmente útil en entornos de baja señal-ruido. Estas predicciones de la rentabilidad esperada son las que alimentan el optimizador.

Conviene subrayar que la incorporación de estas predicciones al modelo de Markowitz preserva su naturaleza de problema de optimización convexa, que puede resolverse de forma exacta con las técnicas descritas por Boyd y Vandenberghe (2004), sin recurrir a heurísticas. Esta combinación de predicción estadística y optimización exacta es el eje metodológico del presente trabajo.

2.6 Evaluación del rendimiento fuera de muestra

La medida estándar para comparar estrategias de inversión es el ratio de Sharpe (1966), que cuantifica la rentabilidad obtenida por unidad de riesgo asumido. Sin embargo, comparar ratios de Sharpe a partir de una muestra finita exige cautela estadística: las diferencias observadas pueden deberse al azar. Memmel (2003) corrigió el contraste de Jobson-Korkie para obtener un test válido de la igualdad de dos ratios de Sharpe, herramienta que este trabajo emplea para evaluar la significancia de sus resultados. La propia metodología de comparación fuera de muestra frente a baselines ingenuos, popularizada por DeMiguel et al. (2009), constituye el estándar metodológico que aquí se adopta.

2.7 Posicionamiento de este trabajo

A la luz de la literatura revisada, este trabajo se sitúa en la intersección de tres líneas: la formulación matemática rigurosa del problema de Markowitz como programa cuadrático convexo resuelto de forma exacta Markowitz, 1952; Boyd y Vandenberghe, 2004; la mitigación del error de estimación tanto en la covarianza —mediante *shrinkage* y un modelo de factores por componentes principales Ledoit y Wolf, 2004; Ross, 1976— como en la rentabilidad esperada —mediante aprendizaje automático Gu et al., 2020—; y la evaluación honesta del rendimiento fuera de muestra con contraste de significancia estadística DeMiguel et al., 2009; Memmel, 2003.

Frente a la abundante literatura de carácter aplicado, que con frecuencia recurre a métodos heurísticos de optimización y a un enfoque orientado al negocio, la aportación diferencial de este trabajo es doble. En primer lugar, el énfasis en el **rigor matemático**: la resolución exacta del problema convexo, el análisis de sus condicio-

nes de optimalidad (KKT) y de su dualidad, y la conexión explícita entre la descomposición espectral de la covarianza y la teoría de factores. En segundo lugar, la **honestidad empírica**: lejos de presentar una estrategia ganadora, el trabajo somete sus resultados a un contraste de significancia estadística y discute con transparencia las condiciones bajo las cuales la optimización ayuda —y aquellas, más frecuentes, en las que el error de estimación impide distinguirla de una diversificación ingenua.

3

Marco teórico financiero

Este capítulo presenta los fundamentos teóricos sobre los que se construye este trabajo. Se comienza con los conceptos de rentabilidad y riesgo, se desarrolla el modelo de selección de carteras de Markowitz y se introducen el ratio de Sharpe y el modelo CAPM como extensiones naturales. La notación que se establece aquí se mantendrá consistente a lo largo de toda la memoria.

3.1 Rentabilidad, riesgo y covarianza

3.1.1 Rentabilidad de un activo

Sea P_t el precio ajustado de un activo financiero en el instante t . La **rentabilidad simple** entre $t - 1$ y t se define como:

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}} = \frac{P_t}{P_{t-1}} - 1. \quad (3.1)$$

En este trabajo se emplea la **rentabilidad logarítmica** (o log-retorno), definida como:

$$r_t = \ln \frac{P_t}{P_{t-1}} = \ln(P_t) - \ln(P_{t-1}). \quad (3.2)$$

La rentabilidad logarítmica presenta dos ventajas fundamentales para el análisis cuantitativo. En primer lugar, es **aditiva en el tiempo**: la rentabilidad acumulada en un período de k días es simplemente la suma de las rentabilidades diarias:

$$r_{t \rightarrow t+k} = \ln \frac{P_{t+k}}{P_t} = \sum_{j=1}^k r_{t+j}. \quad (3.3)$$

Esta propiedad es la que permite agregar rentabilidades diarias a frecuencias mayores (semanal, mensual) mediante una simple suma, y es la que explotamos al pasar de datos diarios a la frecuencia mensual de nuestro backtesting.

En segundo lugar, para pequeñas variaciones diarias ($|R_t| \ll 1$), se tiene $r_t \approx$

R_t , por lo que los log-retornos heredan la interpretabilidad de las rentabilidades simples.

3.1.2 Riesgo: volatilidad

El **riesgo** de un activo se cuantifica mediante la **volatilidad** σ , definida como la desviación típica de sus rentabilidades:

$$\sigma = \sqrt{\text{Var}[r]} = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (r_t - \bar{r})^2}, \quad (3.4)$$

donde $\bar{r} = \frac{1}{T} \sum_{t=1}^T r_t$ es la rentabilidad media muestral. La volatilidad se expresa típicamente en términos anualizados; si r es una rentabilidad diaria, $\sigma_{\text{anual}} = \sigma \cdot \sqrt{252}$, y si r es mensual, $\sigma_{\text{anual}} = \sigma \cdot \sqrt{12}$.

3.1.3 Covarianza y correlación

Dados dos activos i y j , su **covarianza** mide la tendencia conjunta de sus rentabilidades:

$$\sigma_{ij} = \text{Cov}[r_i, r_j] = \frac{1}{T-1} \sum_{t=1}^T (r_{it} - \bar{r}_i)(r_{jt} - \bar{r}_j). \quad (3.5)$$

La **matriz de covarianza** $\Sigma = [\sigma_{ij}] \in \mathbb{R}^{n \times n}$ recoge las covarianzas entre todos los pares de activos de un universo de n títulos. Es simétrica ($\sigma_{ij} = \sigma_{ji}$) y semidefinida positiva ($\mathbf{x}^T \Sigma \mathbf{x} \geq 0$ para todo $\mathbf{x} \in \mathbb{R}^n$).

La **correlación** normaliza la covarianza al intervalo $[-1, 1]$:

$$\rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \sigma_j}, \quad (3.6)$$

donde $\sigma_i = \sqrt{\sigma_{ii}}$ es la volatilidad del activo i .

3.1.4 El principio de diversificación

La varianza de una cartera con pesos $\mathbf{w} = (w_1, \dots, w_n)^T$ es:

$$\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w} = \sum_{i=1}^n w_i^2 \sigma_i^2 + \sum_{i=1}^n \sum_{\substack{j=1 \\ j \neq i}}^n w_i w_j \sigma_{ij}. \quad (3.7)$$

El primer sumando recoge las **varianzas propias** de cada activo; el segundo, los **términos de covarianza** entre pares de activos. Es este segundo bloque el que hace que el riesgo de la cartera no sea, en general, la suma ponderada de los riesgos individuales.

En efecto, cuando los activos no están perfectamente correlacionados, la desviación típica de la cartera satisface

$$\sigma_p \leq \sum_{i=1}^n w_i \sigma_i \quad (w_i \geq 0), \quad (3.8)$$

con igualdad si y solo si todas las correlaciones valen 1. Combinar activos imperfectamente correlacionados reduce, por tanto, el riesgo por debajo de la media ponderada de los riesgos individuales sin sacrificar rentabilidad esperada: esta es la esencia de la **diversificación** y el punto de partida del modelo de Markowitz. La descomposición del riesgo en una componente *diversificable* (idiosincrásica) y otra *no diversificable* (sistemática) no se sigue de (3.7) por sí sola, sino que se formaliza mediante modelos de factores como el CAPM —que se presenta al final de este capítulo— y el APT (Capítulo 5).

3.2 Teoría Moderna de Carteras de Markowitz

En su artículo seminal de 1952, Harry Markowitz propuso un marco matemático para construir carteras óptimas a partir de dos criterios contrapuestos: maximizar la rentabilidad esperada y minimizar el riesgo [Markowitz, 1952](#).

3.2.1 Rentabilidad y riesgo de una cartera

Sea $\mathbf{w} \in \mathbb{R}^n$ el vector de pesos de una cartera, donde w_i representa la fracción de capital invertida en el activo i . Sea $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T$ el vector de rentabilidades esperadas de los activos, con $\mu_i = \mathbb{E}[r_i]$.

La **rentabilidad esperada** de la cartera es la combinación lineal de las rentabilidades esperadas de sus componentes:

$$\mu_p = \mathbb{E}[r_p] = \mathbb{E}\left[\sum_{i=1}^n w_i r_i\right] = \sum_{i=1}^n w_i \mathbb{E}[r_i] = \mathbf{w}^T \boldsymbol{\mu}. \quad (3.9)$$

La **varianza** de la cartera viene dada por la forma cuadrática (3.7), que en notación matricial se escribe:

$$\sigma_p^2 = \text{Var}[r_p] = \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w}. \quad (3.10)$$

3.2.2 El problema de optimización media-varianza

Markowitz formula la selección de carteras como un problema de optimización bicriterio: maximizar μ_p y minimizar σ_p^2 . Esto da lugar a dos formulaciones equivalentes:

1. **Minimizar el riesgo** dada una rentabilidad objetivo μ^* :

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} \\ \text{s.a.} \quad & \mathbf{w}^T \boldsymbol{\mu} \geq \mu^*, \\ & \sum_{i=1}^n w_i = 1. \end{aligned} \quad (3.11)$$

2. **Maximizar la rentabilidad** dado un nivel de riesgo σ_* :

$$\begin{aligned} \max_{\mathbf{w}} \quad & \mathbf{w}^T \boldsymbol{\mu} \\ \text{s.a.} \quad & \mathbf{w}^T \Sigma \mathbf{w} \leq \sigma_*^2, \\ & \sum_{i=1}^n w_i = 1. \end{aligned} \quad (3.12)$$

Ambas formulaciones son **programas cuadráticos convexos** (QP) y, bajo condiciones adecuadas, producen la misma frontera eficiente (ver Capítulo 4 para el desarrollo matemático completo). En este trabajo se utiliza la primera formulación, que resulta computacionalmente más conveniente.

Además de la restricción de presupuesto ($\sum_i w_i = 1$), se imponen dos restricciones adicionales por realismo práctico:

- **Long-only** ($w_i \geq 0$): no se permiten ventas en corto.
- **Tope por activo** ($w_i \leq w_{\max}$): se limita la concentración en un solo título (típicamente $w_{\max} = 0,20$).

3.3 Frontera eficiente y cartera tangente

3.3.1 Definición de frontera eficiente

Al resolver el problema (3.11) para distintos valores del target μ^* , se obtiene una familia de carteras óptimas. En el plano (σ_p, μ_p) , estas carteras describen una curva denominada **frontera eficiente**: para cada nivel de riesgo, la cartera que maximiza la rentabilidad esperada; equivalentemente, para cada nivel de rentabilidad, la cartera que minimiza el riesgo.

- Las carteras por debajo de la frontera son **ineficientes**: existe otra cartera con mayor rentabilidad para el mismo riesgo (o menor riesgo para la misma rentabilidad).
- Las carteras por encima de la frontera son **inalcanzables** con el universo de activos y las restricciones dadas.

3.3.2 Cartera de mínima varianza global (GMV)

El extremo izquierdo de la frontera es la **cartera de mínima varianza global** (GMV, por sus siglas en inglés). Se obtiene resolviendo el QP sin restricción de rentabilidad objetivo:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \mathbf{w}^T \mathbf{\Sigma} \mathbf{w} \\ \text{s.a.} \quad & \sum_{i=1}^n w_i = 1, \quad \mathbf{w} \geq \mathbf{0}. \end{aligned} \quad (3.13)$$

La GMV es la cartera de menor riesgo posible dentro del universo de activos y no depende de μ (solo de Σ). Esta propiedad la convierte en una referencia especialmente útil: su rendimiento depende exclusivamente de la calidad de la estimación de la matriz de covarianza.

3.3.3 Cartera tangente y máximo ratio de Sharpe

El **ratio de Sharpe** [Sharpe, 1966](#) mide el exceso de rentabilidad por unidad de riesgo:

$$S_p = \frac{\mu_p - r_f}{\sigma_p}, \quad (3.14)$$

donde r_f es la tasa libre de riesgo (que en este trabajo se toma como $r_f = 0$ por simplicidad, dado que los tipos de interés de referencia se mantuvieron próximos a cero durante buena parte del período de estudio).

La **cartera tangente** (o de máximo ratio de Sharpe) es el punto de la frontera eficiente cuya recta desde el activo libre de riesgo es tangente a la frontera. Representa la combinación óptima de activos con riesgo para cualquier inversor que pueda prestar o pedir prestado al tipo r_f , de acuerdo con el teorema de separación de Tobin [Tobin, 1958](#).

En presencia de restricciones de desigualdad ($w_i \geq 0, w_i \leq w_{\max}$), la cartera tangente no admite una expresión analítica cerrada y debe obtenerse numéricamente, por ejemplo barriando la frontera eficiente y seleccionando el punto con mayor ratio de Sharpe, que es el enfoque adoptado en nuestra implementación.

3.4 Capital Market Line y CAPM

3.4.1 Capital Market Line (CML)

En el plano (σ_p, μ_p) , la **línea del mercado de capitales** (CML) es la semirrecta que parte de $(0, r_f)$ y es tangente a la frontera eficiente en la cartera tangente $T = (\sigma_T, \mu_T)$. Su ecuación es:

$$\mu_p = r_f + \frac{\mu_T - r_f}{\sigma_T} \sigma_p. \quad (3.15)$$

Cualquier punto sobre la CML representa una combinación del activo libre de riesgo y la cartera tangente T , y domina a cualquier cartera sobre la frontera eficiente

original (excepto en el punto de tangencia).

3.4.2 Capital Asset Pricing Model (CAPM)

El CAPM, desarrollado por Sharpe [Sharpe, 1964](#) y Lintner [Lintner, 1965](#), extiende el modelo de Markowitz introduciendo el concepto de equilibrio de mercado. Su ecuación fundamental es:

$$\mathbb{E}[r_i] - r_f = \beta_i (\mathbb{E}[r_m] - r_f), \quad (3.16)$$

donde $\beta_i = \text{Cov}[r_i, r_m] / \text{Var}[r_m]$ mide la sensibilidad del activo i a los movimientos del mercado, y r_m es la rentabilidad de la cartera de mercado.

El CAPM predice que, en equilibrio, toda la rentabilidad esperada de un activo se explica por su exposición al riesgo sistemático (no diversificable), medido por β_i . El riesgo idiosincrásico no es remunerado porque puede eliminarse mediante diversificación.

Aunque el CAPM es un modelo de equilibrio y el modelo de Markowitz es un modelo normativo (prescribe qué cartera debería elegir un inversor), ambos comparten la misma estructura media-varianza. La conexión con el CAPM es relevante para este trabajo en dos sentidos. Primero, justifica el uso del SPY (un proxy de la cartera de mercado) como baseline. Segundo, la estimación de la matriz de covarianza mediante PCA y modelos de factores (Capítulo 5) conecta directamente con la idea de separar el riesgo sistemático del idiosincrásico, que es la esencia del CAPM.

3.5 Síntesis y conexión con el resto del trabajo

El modelo de Markowitz proporciona un marco riguroso para la selección de carteras, pero su implementación requiere estimar dos conjuntos de parámetros: μ y Σ . La calidad de estas estimaciones determina el rendimiento out-of-sample de las carteras optimizadas.

Los capítulos siguientes abordan precisamente esta cuestión. El Capítulo 4 desarrolla la formulación matemática completa del QP, incluyendo las condiciones de optimalidad y la solución analítica. El Capítulo 5 analiza las consecuencias del error de estimación y presenta estimadores robustos de Σ (shrinkage, PCA). El Capítulo 6 explora si el Machine Learning puede mejorar la estimación de μ .

Bibliografía

Areia, José (dic. de 2023). *Polytechnic University of Leiria: LaTeX Thesis Template*. URL: <https://github.com/joseareia/ipleiria-thesis>.

Best, Michael J. y Robert R. Grauer (1991). «On the sensitivity of mean-variance-efficient portfolios to changes in asset means: some analytical and computational results». En: *The Review of Financial Studies* 4.2, págs. 315-342.

Black, Fischer y Robert Litterman (1992). «Global portfolio optimization». En: *Financial Analysts Journal* 48.5, págs. 28-43.

Boyd, Stephen y Lieven Vandenberghe (2004). *Convex Optimization*. Cambridge University Press.

Breiman, Leo (2001). «Random Forests». En: *Machine Learning* 45.1, págs. 5-32.

Cont, Rama (2001). «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues». En: *Quantitative Finance* 1.2, págs. 223-236.

DeMiguel, Victor, Lorenzo Garlappi y Raman Uppal (2009). «Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy?» En: *The Review of Financial Studies* 22.5, págs. 1915-1953.

Fama, Eugene F. y Kenneth R. French (1993). «Common risk factors in the returns on stocks and bonds». En: *Journal of Financial Economics* 33.1, págs. 3-56.

Gu, Shihao, Bryan Kelly y Dacheng Xiu (2020). «Empirical Asset Pricing via Machine Learning». En: *The Review of Financial Studies* 33.5, págs. 2223-2273.

Jegadeesh, Narasimhan y Sheridan Titman (1993). «Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency». En: *The Journal of Finance* 48.1, págs. 65-91.

Jorion, Philippe (1986). «Bayes-Stein estimation for portfolio analysis». En: *Journal of Financial and Quantitative Analysis* 21.3, págs. 279-292.

Ledoit, Olivier y Michael Wolf (2004). «A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices». En: *Journal of Multivariate Analysis* 88.2, págs. 365-411.

- Lintner, John (1965). «The Valuation of Risk Assets and the Selection of Risky Investments in Stock Portfolios and Capital Budgets». En: *The Review of Economics and Statistics* 47.1, págs. 13-37.
- Markowitz, Harry (1952). «Portfolio Selection». En: *The Journal of Finance* 7.1, págs. 77-91.
- Memmel, Christoph (2003). «Performance hypothesis testing with the Sharpe ratio». En: *Finance Letters* 1.1, págs. 21-23.
- Merton, Robert C. (1972). «An Analytic Derivation of the Efficient Portfolio Frontier». En: *The Journal of Financial and Quantitative Analysis* 7.4, págs. 1851-1872.
- Merton, Robert C. (1980). «On Estimating the Expected Return on the Market: An Exploratory Investigation». En: *Journal of Financial Economics* 8.4, págs. 323-361.
- Michaud, Richard O. (1989). «The Markowitz optimization enigma: is .°ptimized.°ptimal?». En: *Financial Analysts Journal* 45.1, págs. 31-42.
- Ross, Stephen A. (1976). «The Arbitrage Theory of Capital Asset Pricing». En: *Journal of Economic Theory* 13.3, págs. 341-360.
- Sharpe, William F. (1964). «Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk». En: *The Journal of Finance* 19.3, págs. 425-442.
- Sharpe, William F. (1966). «Mutual Fund Performance». En: *The Journal of Business* 39.1, págs. 119-138.
- Tobin, James (1958). «Liquidity Preference as Behavior Towards Risk». En: *The Review of Economic Studies* 25.2, págs. 65-86.
- Zou, Hui y Trevor Hastie (2005). «Regularization and Variable Selection via the Elastic Net». En: *Journal of the Royal Statistical Society: Series B* 67.2, págs. 301-320.