

# Optimización de carteras: integración de la Teoría de Markowitz con técnicas de Machine Learning

*Trabajo Fin de Grado*

**Ricardo Marín Fernández-Conde**

Escuela Politécnica Superior  
Departamento de Matemáticas y Ciencia de Datos  
Grado en Ingeniería Matemática

Madrid, julio 2026

# Optimización de carteras: integración de la Teoría de Markowitz con técnicas de Machine Learning

*Trabajo Fin de Grado*

**Ricardo Marín Fernández-Conde**

**Director:** Alfredo Sánchez Alberca  
*Profesor, Escuela Politécnica  
Superior*

Escuela Politécnica Superior  
Departamento de Matemáticas y Ciencia de Datos  
Grado en Ingeniería Matemática

Madrid, julio 2026

## **Optimización de carteras: integración de la Teoría de Markowitz con técnicas de Machine Learning**

Copyright © 2026 - Ricardo Marín Fernández-Conde, Escuela Politécnica Superior.

Esta disertación es un trabajo original, redactado exclusivamente para este fin, y todos los autores cuyos estudios y publicaciones contribuyeron a la misma han sido debidamente citados. Se permite la reproducción parcial con reconocimiento del autor y referencia al grado, curso académico, institución—*Universidad CEU San Pablo*—y fecha de la defensa pública.



# Agradecimientos

Quiero dar las gracias a mi director, Alfredo Sánchez Alberca, por su orientación, su paciencia y su dedicación a lo largo de este trabajo. Y a mi familia, por su apoyo constante durante toda la carrera.

Esta memoria se ha elaborado con la plantilla CEUTFG, basada en la plantilla *Polytechnic University of Leiria: LaTeX Thesis Template* ([Areia, José, 2023](#)).

# Resumen

La selección óptima de carteras según el modelo media-varianza de Markowitz depende de la estimación de dos parámetros: el vector de rentabilidades esperadas  $\mu$  y la matriz de covarianza  $\Sigma$ . Este trabajo formula el modelo como un problema cuadrático convexo (QP), lo resuelve de forma exacta a través de sus condiciones de Karush-Kuhn-Tucker (KKT) y evalúa hasta qué punto varias técnicas estadísticas y de *Machine Learning* mejoran la estimación de esos parámetros. Sobre una muestra de 30 acciones del S&P 500 (2010–2024), se comparan tres estimadores de la covarianza (muestral, *shrinkage* de Ledoit-Wolf y reconstrucción por componentes principales, PCA) y tres modelos de predicción de  $\mu$  (Ridge, Lasso y Random Forest), validados mediante *backtesting* walk-forward sin *look-ahead* frente a los *baselines* 1/N (equiponderada) y el índice de mercado (SPY). El *shrinkage* y el PCA mejoran de forma modesta la cartera muestral (Sharpe 0,68 y 0,69 frente a 0,64). Entrenados de forma agrupada, los modelos de *Machine Learning* resultan competitivos: Lasso (Sharpe 0,75) llega a igualar a la estrategia 1/N (0,76). Aun así, ninguna cartera optimizada supera al mercado (Sharpe 0,90) y, sobre todo, ninguna diferencia de Sharpe es estadísticamente significativa. La principal contribución no es un modelo que bata al mercado, sino una demostración rigurosa de por qué el error de estimación domina el problema, hasta hacer indistinguibles las estrategias, y de qué técnicas ayudan a mitigarlo.

**Palabras-Clave:** Optimización de carteras, Modelo de Markowitz, Programación cuadrática convexa, Shrinkage de Ledoit-Wolf, Machine Learning, Backtesting walk-forward.

# Abstract

Optimal portfolio selection under Markowitz’s mean–variance model depends on estimating two parameters: the vector of expected returns  $\mu$  and the covariance matrix  $\Sigma$ . This work formulates the model as a convex quadratic program (QP), solves it exactly through its Karush-Kuhn-Tucker (KKT) conditions, and empirically assesses how far statistical and *Machine Learning* techniques improve the estimation of these parameters. Using a sample of 30 S&P 500 stocks (2010–2024), three covariance estimators (sample, Ledoit-Wolf *shrinkage* and principal-component (PCA) reconstruction) and three models for predicting  $\mu$  (Ridge, Lasso and Random Forest) are compared, all validated through walk-forward *backtesting* without *look-ahead* against the  $1/N$  (equally weighted) and market-index (SPY) baselines. Shrinkage and PCA modestly improve the sample portfolio (Sharpe 0,68 and 0,69 vs. 0,64). When trained in a pooled fashion, the *Machine Learning* models are competitive: Lasso (Sharpe 0,75) matches the  $1/N$  strategy (0,76). Nevertheless, no optimized portfolio beats the market (Sharpe 0,90) and, crucially, none of the Sharpe differences is statistically significant. The main contribution is not a model that beats the market, but a rigorous demonstration of why estimation error dominates the problem, to the point of making the strategies indistinguishable, and of which techniques help to mitigate it.

**Keywords:** Portfolio optimization, Markowitz model, Convex quadratic programming, Ledoit-Wolf shrinkage, Machine Learning, Walk-forward backtesting.

# Declaración sobre el Uso de Inteligencia Artificial

Declaro que durante la realización de este Trabajo Fin de Grado he empleado herramientas de inteligencia artificial (en concreto, Claude y ChatGPT) como apoyo en las siguientes tareas:

- **Programación.** Ayuda en la implementación y depuración del código en Python: la descarga y el preprocesado de los datos, los estimadores de la matriz de covarianza (muestral, *shrinkage* de Ledoit-Wolf y PCA), la resolución del problema de optimización de Markowitz con *cvxpy*, los modelos de aprendizaje automático (Ridge, Lasso y Random Forest), el motor de *backtesting* walk-forward y los contrastes de significancia estadística. También en la explicación de las operaciones no triviales del código.
- **Búsqueda y gestión de fuentes.** Ayuda en la localización y verificación de referencias académicas y en la organización de la bibliografía.
- **Desarrollo de ideas y metodología.** Apoyo en la discusión del enfoque matemático y de las decisiones metodológicas del trabajo.
- **Revisión y corrección.** Ayuda en la detección de errores e incoherencias en el contenido y en la revisión lingüística del texto.

En todos los casos he empleado estas herramientas como una ayuda, y no como sustituto del criterio propio. He supervisado, revisado y validado la totalidad del contenido, y asumo la plena responsabilidad sobre las decisiones metodológicas, los resultados, las conclusiones y la redacción final del trabajo.

# Índice general

|                                                                      |           |
|----------------------------------------------------------------------|-----------|
| <i>Índice de figuras</i>                                             | IX        |
| <i>Índice de cuadros</i>                                             | X         |
| <b>Glosario de términos y siglas</b>                                 | <b>XI</b> |
| <b>1. Introducción</b>                                               | <b>1</b>  |
| 1.1. Motivación y contexto . . . . .                                 | 1         |
| 1.2. Planteamiento del problema . . . . .                            | 1         |
| 1.3. Objetivos . . . . .                                             | 1         |
| 1.3.1. Objetivo general . . . . .                                    | 1         |
| 1.3.2. Objetivos específicos . . . . .                               | 1         |
| 1.4. Estructura del documento . . . . .                              | 2         |
| <b>2. Estado del arte</b>                                            | <b>3</b>  |
| 2.1. De la teoría moderna de carteras al CAPM y la APT . . . . .     | 3         |
| 2.2. El problema del error de estimación . . . . .                   | 3         |
| 2.3. Mejoras en la estimación de la matriz de covarianza . . . . .   | 4         |
| 2.4. Enfoques bayesianos e incorporación de visiones . . . . .       | 4         |
| 2.5. Predicción de rentabilidades y aprendizaje automático . . . . . | 4         |
| 2.6. Evaluación del rendimiento fuera de muestra . . . . .           | 5         |
| 2.7. Posicionamiento de este trabajo . . . . .                       | 5         |
| <b>3. Marco teórico financiero</b>                                   | <b>6</b>  |
| 3.1. Rentabilidad, riesgo y covarianza . . . . .                     | 6         |
| 3.1.1. Rentabilidad de un activo . . . . .                           | 6         |
| 3.1.2. Riesgo: volatilidad . . . . .                                 | 7         |
| 3.1.3. Covarianza y correlación . . . . .                            | 7         |
| 3.1.4. El principio de diversificación . . . . .                     | 7         |
| 3.2. Teoría Moderna de Carteras de Markowitz . . . . .               | 8         |
| 3.2.1. Rentabilidad y riesgo de una cartera . . . . .                | 8         |
| 3.2.2. El problema de optimización media-varianza . . . . .          | 8         |
| 3.3. Frontera eficiente y cartera tangente . . . . .                 | 9         |
| 3.3.1. Definición de frontera eficiente . . . . .                    | 9         |
| 3.3.2. Cartera de mínima varianza global (GMV) . . . . .             | 9         |
| 3.3.3. Cartera tangente y máximo ratio de Sharpe . . . . .           | 9         |
| 3.4. Capital Market Line y CAPM . . . . .                            | 9         |
| 3.4.1. Capital Market Line (CML) . . . . .                           | 9         |
| 3.4.2. Capital Asset Pricing Model (CAPM) . . . . .                  | 10        |



|                                                                                     |           |
|-------------------------------------------------------------------------------------|-----------|
| 3.5. Síntesis y conexión con el resto del trabajo . . . . .                         | 10        |
| <b>4. Formulación matemática del problema</b>                                       | <b>11</b> |
| 4.1. El modelo media-varianza como problema de optimización . . . . .               | 11        |
| 4.1.1. Notación . . . . .                                                           | 11        |
| 4.1.2. Formulación primal . . . . .                                                 | 11        |
| 4.2. Convexidad del problema cuadrático . . . . .                                   | 12        |
| 4.2.1. Convexidad de la función objetivo . . . . .                                  | 12        |
| 4.2.2. Convexidad de la región factible . . . . .                                   | 12        |
| 4.3. Condiciones de Karush-Kuhn-Tucker (KKT) . . . . .                              | 13        |
| 4.4. Dualidad e interpretación económica . . . . .                                  | 14        |
| 4.4.1. El problema dual . . . . .                                                   | 14        |
| 4.4.2. Interpretación de los multiplicadores . . . . .                              | 14        |
| 4.5. Solución analítica de la frontera eficiente . . . . .                          | 14        |
| 4.6. Del caso analítico al caso con restricciones . . . . .                         | 15        |
| <b>5. Limitaciones del modelo clásico</b>                                           | <b>16</b> |
| 5.1. El error de estimación y sus consecuencias . . . . .                           | 16        |
| 5.1.1. Dimensionalidad y escasez de datos . . . . .                                 | 16        |
| 5.1.2. El problema de la estimación de $\mu$ . . . . .                              | 16        |
| 5.2. Inestabilidad y concentración de los pesos . . . . .                           | 17        |
| 5.2.1. Demostración empírica . . . . .                                              | 17        |
| 5.2.2. Evolución temporal de la concentración . . . . .                             | 17        |
| 5.3. Estimación robusta de la covarianza: shrinkage de Ledoit-Wolf . . . . .        | 18        |
| 5.3.1. Fundamento teórico . . . . .                                                 | 18        |
| 5.3.2. Efecto sobre la cartera . . . . .                                            | 19        |
| 5.4. Covarianza basada en PCA y modelos de factores . . . . .                       | 19        |
| 5.4.1. Selección del número de factores . . . . .                                   | 19        |
| 5.4.2. Conexión con la Arbitrage Pricing Theory (APT) . . . . .                     | 20        |
| 5.5. Síntesis: del error de estimación a la necesidad de Machine Learning . . . . . | 20        |
| <b>6. Machine Learning para la predicción de <math>\mu</math></b>                   | <b>21</b> |
| 6.1. Planteamiento del problema predictivo . . . . .                                | 21        |
| 6.1.1. ¿Por qué Machine Learning? . . . . .                                         | 21        |
| 6.1.2. Configuración del problema . . . . .                                         | 22        |
| 6.2. Ingeniería de características (features) . . . . .                             | 22        |
| 6.2.1. Features basadas en rentabilidades pasadas . . . . .                         | 22        |
| 6.2.2. Features del mercado . . . . .                                               | 22        |
| 6.3. Modelos de Machine Learning . . . . .                                          | 23        |
| 6.3.1. Ridge (regularización L2) . . . . .                                          | 23        |
| 6.3.2. Lasso (regularización L1) . . . . .                                          | 23        |
| 6.3.3. Random Forest . . . . .                                                      | 24        |
| 6.4. Validación temporal (walk-forward) . . . . .                                   | 24        |
| 6.4.1. El peligro del look-ahead . . . . .                                          | 24        |
| 6.4.2. Protocolo de backtesting . . . . .                                           | 24        |
| 6.4.3. Métricas de evaluación predictiva . . . . .                                  | 24        |
| 6.5. Conexión con la optimización de carteras . . . . .                             | 25        |
| 6.6. Síntesis . . . . .                                                             | 25        |

|                                                                    |           |
|--------------------------------------------------------------------|-----------|
| <b>7. Metodología y diseño experimental</b>                        | <b>26</b> |
| 7.1. Datos . . . . .                                               | 26        |
| 7.1.1. Universo de activos . . . . .                               | 26        |
| 7.1.2. Periodo y frecuencia . . . . .                              | 26        |
| 7.1.3. Fuente y preprocesado . . . . .                             | 27        |
| 7.2. Esquema de backtesting walk-forward . . . . .                 | 27        |
| 7.2.1. Parámetros del backtesting . . . . .                        | 27        |
| 7.2.2. Procedimiento mensual . . . . .                             | 27        |
| 7.2.3. Prevención del look-ahead . . . . .                         | 28        |
| 7.3. Carteras evaluadas . . . . .                                  | 28        |
| 7.4. Métricas de evaluación . . . . .                              | 28        |
| 7.4.1. Métricas de rentabilidad-riesgo . . . . .                   | 28        |
| 7.4.2. Métricas de composición de cartera . . . . .                | 29        |
| 7.4.3. Métricas de predicción ML . . . . .                         | 29        |
| 7.5. Implementación y reproducibilidad . . . . .                   | 29        |
| 7.6. Síntesis . . . . .                                            | 30        |
| <b>8. Resultados y discusión</b>                                   | <b>31</b> |
| 8.1. Comparación global de carteras . . . . .                      | 31        |
| 8.1.1. Resultado principal . . . . .                               | 32        |
| 8.1.2. Rentabilidad frente a riesgo . . . . .                      | 32        |
| 8.2. Efecto del estimador de covarianza . . . . .                  | 32        |
| 8.3. Efecto de la predicción ML de $\mu$ . . . . .                 | 33        |
| 8.3.1. Rendimiento de las carteras ML . . . . .                    | 33        |
| 8.3.2. Análisis del rendimiento de los modelos ML . . . . .        | 33        |
| 8.3.3. Turnover y costes de transacción . . . . .                  | 33        |
| 8.4. Estabilidad temporal . . . . .                                | 34        |
| 8.5. Significación estadística . . . . .                           | 34        |
| 8.6. Discusión crítica . . . . .                                   | 35        |
| 8.6.1. ¿Por qué no se batan los baselines pasivos? . . . . .       | 35        |
| 8.6.2. Limitaciones del estudio . . . . .                          | 35        |
| 8.6.3. Implicaciones . . . . .                                     | 35        |
| <b>9. Conclusiones y líneas futuras</b>                            | <b>36</b> |
| 9.1. Conclusiones . . . . .                                        | 36        |
| 9.1.1. Sobre la formulación matemática . . . . .                   | 36        |
| 9.1.2. Sobre la estimación de la covarianza . . . . .              | 36        |
| 9.1.3. Sobre la predicción de $\mu$ con Machine Learning . . . . . | 37        |
| 9.1.4. Sobre la comparación con baselines pasivos . . . . .        | 37        |
| 9.1.5. Conclusión final . . . . .                                  | 37        |
| 9.2. Líneas futuras de investigación . . . . .                     | 37        |
| <i>Bibliografía</i>                                                | 39        |

|                                                                          |           |
|--------------------------------------------------------------------------|-----------|
| <b>A. Solución analítica de la frontera eficiente</b>                    | <b>42</b> |
| A.1. Caso sin restricciones de desigualdad . . . . .                     | 42        |
| A.2. Derivación mediante multiplicadores de Lagrange . . . . .           | 42        |
| A.3. Ecuación de la frontera eficiente . . . . .                         | 43        |
| A.4. Cartera de mínima varianza global (GMV) . . . . .                   | 43        |
| A.5. Cartera de máximo ratio de Sharpe . . . . .                         | 44        |
| A.6. Validación con la implementación numérica . . . . .                 | 44        |
| <b>B. Desarrollos matemáticos complementarios</b>                        | <b>45</b> |
| B.1. Condiciones de Karush-Kuhn-Tucker: planteamiento general . . . . .  | 45        |
| B.2. Lagrangiano del QP de Markowitz . . . . .                           | 45        |
| B.3. Estimador de covarianza por PCA y equivalencia con la APT . . . . . | 46        |

# Índice de figuras

|      |                                                                                                                                                                                                          |    |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 5.1. | Evolución del índice Herfindahl-Hirschman (HHI) de la cartera GMV con ventanas móviles de 36 meses. La línea gris discontinua marca el HHI de la cartera equiponderada ( $1/30 \approx 0,033$ ). . . . . | 18 |
| 5.2. | Pesos de la cartera GMV según el estimador de $\Sigma$ (solo activos con peso $> 2\%$ en al menos un estimador). . . . .                                                                                 | 19 |
| 5.3. | Descomposición espectral de la covarianza muestral. Barras: autovalores (eje izquierdo). Línea: varianza explicada acumulada (eje derecho). . .                                                          | 20 |
| 8.1. | Ratio de Sharpe anualizado por estrategia. . . . .                                                                                                                                                       | 31 |
| 8.2. | Evolución de 1€ invertido en cada estrategia durante el periodo out-of-sample (2013–2024). Las líneas discontinuas representan los baselines pasivos. . . . .                                            | 32 |

# Índice de cuadros

|                                                                                                                                                                                                                                                                                                                                                              |    |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 5.1. Comparación de carteras GMV según el estimador de $\Sigma$ . Ventana: 2022–2024 (36 meses).                                                                                                                                                                                                                                                             | 17 |
| 6.1. Features utilizadas para la predicción de $r_{i,t+1}$ .                                                                                                                                                                                                                                                                                                 | 23 |
| 7.1. Universo de 30 activos por sector GICS.                                                                                                                                                                                                                                                                                                                 | 26 |
| 7.2. Carteras evaluadas en el experimento.                                                                                                                                                                                                                                                                                                                   | 28 |
| 8.1. Resultados completos del backtesting walk-forward (enero 2013 – diciembre 2024, 143 meses).                                                                                                                                                                                                                                                             | 31 |
| 8.2. Significación estadística de los ratios de Sharpe: intervalo de confianza al 95 % por <i>bootstrap</i> y <i>p</i> -valor del test de Memmel frente a cada baseline. El Sharpe de esta tabla se calcula como media/desviación típica mensual anualizada, ligeramente superior al de la Tabla 8.1 (geométrico) por el efecto del <i>volatility drag</i> . | 34 |

# Glosario de términos y siglas

## Términos

- Backtesting** Evaluación de una estrategia de inversión reproduciéndola sobre datos históricos.
- Walk-forward** Esquema de *backtesting* con ventana móvil que, en cada instante, estima y decide usando únicamente información pasada.
- Look-ahead (sesgo de)** Uso indebido de información futura, no disponible en el momento de la decisión; error que debe evitarse en todo el *backtesting*.
- Out-of-sample (fuera de muestra)** Datos que no se han empleado para estimar los parámetros ni para entrenar los modelos, y sobre los que se mide el rendimiento real.
- Baseline** Estrategia de referencia con la que se comparan las demás; aquí, la cartera equiponderada  $1/N$  y el índice de mercado (SPY).
- Turnover** Rotación de la cartera de un rebalanceo al siguiente; se emplea como aproximación de los costes de transacción.
- Drawdown (máximo)** Mayor caída, de un máximo previo a un mínimo posterior, del valor acumulado de la cartera.
- Shrinkage** Técnica que contrae la matriz de covarianza muestral hacia una matriz estructurada y estable, reduciendo el error de estimación.
- Sparse (dispersa)** Solución con muchos coeficientes exactamente iguales a cero, característica de la regularización del Lasso.
- Ratio de Sharpe** Rentabilidad obtenida por unidad de riesgo (volatilidad).
- Pooled (agrupado)** Entrenamiento de un único modelo con las observaciones de todos los activos a la vez, en lugar de uno por activo.
- Feature** Característica o variable de entrada que utiliza el modelo de predicción.
- Precio sombra** Valor del multiplicador de una restricción; mide cuánto mejoraría el óptimo si esa restricción se relajara en una unidad.

## Siglas

- QP** Programa cuadrático (*Quadratic Program*).
- KKT** Karush-Kuhn-Tucker (condiciones de optimalidad).
- ML** *Machine Learning* (aprendizaje automático).
- PCA** Análisis de componentes principales.
- APT** *Arbitrage Pricing Theory* (teoría de valoración por arbitraje).
- GMV** Cartera de mínima varianza global.
- CAPM** *Capital Asset Pricing Model*.
- CML** *Capital Market Line*.

**HHI** Índice de Herfindahl-Hirschman (concentración de la cartera).

**MDD** Máximo *drawdown*.

**RMSE / MAE** Error cuadrático medio / error absoluto medio.

**SPY** ETF que replica el índice S&P 500 (proxy de la cartera de mercado).

# 1

## Introducción

### 1.1 Motivación y contexto

La gestión cuantitativa de inversiones ha cambiado mucho en las últimas décadas. El modelo de selección de carteras de Harry Markowitz (1952) puso las bases matemáticas de la diversificación y del equilibrio entre rentabilidad y riesgo. En la práctica, sin embargo, choca con un problema: hay que estimar sus parámetros de entrada, y sobre todo las rentabilidades esperadas de los activos.

### 1.2 Planteamiento del problema

El modelo de Markowitz necesita como entradas el vector de rentabilidades esperadas  $\mu$  y la matriz de covarianza  $\Sigma$ . La matriz  $\Sigma$  se estima con cierta estabilidad a partir de datos históricos, y todavía mejora con técnicas de shrinkage. Estimar  $\mu$ , en cambio, es mucho más difícil: pequeños errores en la predicción de rentabilidades dan carteras muy distintas y, a menudo, peores que un simple reparto equiponderado [DeMiguel et al., 2009](#).

Este trabajo estudia si el Machine Learning puede mejorar la predicción de  $\mu$  y, con ello, el rendimiento *out-of-sample* (fuera de la muestra de estimación) de las carteras optimizadas.

### 1.3 Objetivos

#### 1.3.1 Objetivo general

Diseñar y evaluar un modelo de optimización de carteras que integre la teoría clásica de Markowitz con técnicas de Machine Learning para la predicción de rentabilidades esperadas.

#### 1.3.2 Objetivos específicos

1. Formular el modelo media-varianza como un problema cuadrático convexo (QP) y resolverlo de forma exacta mediante `cvxpy`.
2. Implementar y comparar tres estimadores de la matriz de covarianza: muestral, shrinkage de Ledoit-Wolf y basado en PCA/factores.



3. Desarrollar modelos de Machine Learning (Ridge, Lasso, Random Forest) para predecir las rentabilidades esperadas de cada activo.
4. Evaluar el rendimiento out-of-sample de las carteras mediante backtesting walk-forward, comparándolas contra baselines relevantes.

## 1.4 Estructura del documento

El resto del documento se organiza como sigue. El Capítulo 2 revisa el estado del arte en optimización de carteras, desde la teoría moderna hasta el aprendizaje automático. El Capítulo 3 presenta el marco teórico financiero. El Capítulo 4 desarrolla la formulación matemática del problema como QP convexo, incluyendo las condiciones KKT y la solución analítica de la frontera eficiente. El Capítulo 5 aborda las limitaciones del modelo clásico y presenta los estimadores robustos de covarianza. El Capítulo 6 describe la aplicación de Machine Learning a la predicción de rentabilidades. El Capítulo 7 detalla la metodología experimental. El Capítulo 8 presenta y discute los resultados. Finalmente, el Capítulo 9 recoge las conclusiones y posibles líneas futuras de investigación.

# 2

## Estado del arte

La optimización de carteras es uno de los problemas más estudiados en finanzas cuantitativas. Desde que se formuló, a mediados del siglo XX, tiene siempre el mismo problema de fondo: un modelo elegante sobre el papel pero frágil en la práctica, porque depende de estimar bien unos parámetros que casi nunca se conocen del todo. Este capítulo repasa cómo ha evolucionado el campo —de la teoría moderna de carteras al aprendizaje automático— para ver qué se ha hecho hasta ahora y dónde encaja este trabajo.

### 2.1 De la teoría moderna de carteras al CAPM y la APT

El punto de partida es [Markowitz \(1952\)](#), que planteó la selección de carteras como un equilibrio entre rentabilidad esperada y riesgo (la varianza). Su idea central: el riesgo de una cartera no es la suma de los riesgos individuales, sino que depende de las covarianzas entre activos; por eso diversificar reduce el riesgo sin renunciar a rentabilidad. Ese marco media-varianza sigue siendo el lenguaje básico de la gestión cuantitativa.

[Tobin \(1958\)](#) añadió el *teorema de separación*: con un activo libre de riesgo, la decisión se parte en dos —elegir la cartera óptima de activos con riesgo (la tangente) y combinarla con el activo seguro—. De ahí surgieron los modelos de equilibrio: el CAPM de [Sharpe \(1964\)](#) y [Lintner \(1965\)](#), según el cual la rentabilidad esperada de un activo depende linealmente de su riesgo sistemático (la beta), y la *Arbitrage Pricing Theory* de [Ross \(1976\)](#), que lo generaliza a varios factores de riesgo y sin supuestos de equilibrio.

En el plano matemático, [Merton \(1972\)](#) obtuvo la solución analítica de la frontera eficiente (sin restricciones de desigualdad) y mostró que las carteras de mínima varianza forman una hipérbola en el plano riesgo-rentabilidad. Ese resultado, que se desarrolla en el Capítulo 4, es la base de la optimización de este trabajo.

### 2.2 El problema del error de estimación

El modelo funciona en teoría, pero se complica al aplicarlo: necesita el vector de rentabilidades esperadas y la matriz de covarianzas, y ninguno se conoce —hay que estimarlos con datos históricos. [Merton \(1980\)](#) avisó de que estimar la rentabilidad

esperada es mucho más difícil que estimar covarianzas: la precisión de estas mejora al muestrear más a menudo, pero la de aquella solo mejora con horizontes muy largos, poco realistas.

Las consecuencias son serias. [Best y Grauer \(1991\)](#) demostraron que las carteras eficientes son muy sensibles a las rentabilidades esperadas estimadas: cambios mínimos en las medias reasignan los pesos por completo. [Michaud \(1989\)](#) definió la optimización media-varianza como un «*maximizador del error de estimación*», porque da pesos desproporcionados a los activos cuya rentabilidad se ha sobrestimado por azar; por eso las carteras “optimizadas” rinden a menudo peor, fuera de muestra, que otras ingenuas.

La evidencia más influyente es la de [DeMiguel et al. \(2009\)](#): compararon catorce modelos de optimización con la regla ingenua  $1/N$  (repartir el capital por igual) y ninguno la batió de forma consistente fuera de muestra; calcularon que harían falta ventanas de miles de meses para que optimizar compensara el error de estimación. Es el referente directo con el que se comparan los resultados de este trabajo.

### 2.3 Mejoras en la estimación de la matriz de covarianza

La covarianza se estima mejor que la rentabilidad esperada, pero también falla cuando el número de activos se acerca al de observaciones: la matriz muestral queda mal condicionada y da carteras inestables. La solución más usada es el *shrinkage* de [Ledoit y Wolf \(2004\)](#), que mezcla la matriz muestral con un objetivo bien condicionado (la identidad escalada) en la proporción óptima; el resultado reduce el error cuadrático medio y da carteras más estables.

Otra vía es imponer una estructura de factores. [Fama y French \(1993\)](#) mostraron que unos pocos factores comunes —mercado, tamaño y valor— explican buena parte de cómo se mueven juntas las rentabilidades. Modelar la covarianza con pocos factores reduce los parámetros a estimar y filtra el ruido propio de cada activo; la idea conecta con la APT de [Ross \(1976\)](#) y con la descomposición en componentes principales que este trabajo usa como tercer estimador (Capítulo 5).

### 2.4 Enfoques bayesianos e incorporación de visiones

Otra familia de soluciones ataca el error en las rentabilidades esperadas con inferencia bayesiana. [Jorion \(1986\)](#) aplicó el estimador de Bayes-Stein, que acerca las rentabilidades esperadas a un valor común y así reduce la varianza del estimador. El más conocido en la práctica es el modelo de [Black y Litterman \(1992\)](#), que combina, de forma bayesiana, las rentabilidades implícitas del mercado con las “visiones” del inversor, y evita las asignaciones extremas. Todos van en la misma dirección que este trabajo —sustituir el estimador ingenuo de la rentabilidad esperada por una predicción mejor informada—, aquí con aprendizaje automático.

### 2.5 Predicción de rentabilidades y aprendizaje automático

¿Se pueden predecir las rentabilidades? La respuesta es a medias. Hay anomalías aprovechables, como el *momentum* de [Jegadeesh y Titman \(1993\)](#) (los activos

que han rendido bien hace poco tienden a seguir), pero [Cont \(2001\)](#) recopiló los *hechos estilizados* de las series financieras —colas pesadas, ausencia de autocorrelación lineal y agrupamiento de la volatilidad—, que limitan mucho esa predictibilidad y desaconsejan suponer normalidad.

En la última década el aprendizaje automático ha crecido mucho en este campo. El estudio de referencia es [Gu et al. \(2020\)](#), que comparó muchos métodos —de regresiones penalizadas a árboles y redes neuronales— para predecir rentabilidades en un panel amplio de acciones. Sus conclusiones encajan con este trabajo: los métodos no lineales captan interacciones que los lineales ignoran, pero las mejoras son pequeñas ( $R^2$  fuera de muestra muy bajos) y la regularización es clave para no sobreajustar con poca señal. De ese catálogo, este trabajo usa los *Random Forests* de [Breiman \(2001\)](#) y dos regresiones regularizadas, *Ridge* y *Lasso*; el *Lasso*, emparentado con la *elastic net* de [Zou y Hastie \(2005\)](#), además selecciona variables por sí solo. Esas predicciones alimentan el optimizador.

Meter estas predicciones en el modelo de Markowitz no le quita su carácter de problema de optimización convexa, que se resuelve de forma exacta con las técnicas de [Boyd y Vandenberghe \(2004\)](#), sin heurísticas. Esa combinación —predicción estadística y optimización exacta— es el enfoque central de este trabajo.

## 2.6 Evaluación del rendimiento fuera de muestra

La medida habitual para comparar estrategias es el ratio de [Sharpe \(1966\)](#) (rentabilidad por unidad de riesgo). Pero compararlo con una muestra finita pide cautela: las diferencias pueden deberse al azar. [Memmel \(2003\)](#) corrigió el contraste de Jobson-Korkie para obtener un test válido de igualdad entre dos ratios de Sharpe, que este trabajo usa para medir la significación de sus resultados. La forma de comparar fuera de muestra frente a baselines ingenuos, popularizada por [DeMiguel et al. \(2009\)](#), es el estándar que se adopta aquí.

## 2.7 Posicionamiento de este trabajo

Con todo lo anterior, este trabajo combina tres líneas: formular el problema de Markowitz con rigor, como un programa cuadrático convexo resuelto de forma exacta [Markowitz, 1952](#); [Boyd y Vandenberghe, 2004](#); reducir el error de estimación en la covarianza —con *shrinkage* y un modelo de factores por componentes principales [Ledoit y Wolf, 2004](#); [Ross, 1976](#)— y en la rentabilidad esperada —con aprendizaje automático [Gu et al., 2020](#)—; y evaluar el rendimiento fuera de muestra de forma honesta, con un contraste de significación [DeMiguel et al., 2009](#); [Memmel, 2003](#).

Frente a buena parte de la literatura aplicada, que suele tirar de métodos heurísticos y de un enfoque de negocio, este trabajo se distingue por dos cosas. La primera, el **rigor matemático**: resolver el problema convexo de forma exacta, analizar sus condiciones de optimalidad (KKT) y su dualidad, y conectar la descomposición espectral de la covarianza con la teoría de factores. La segunda, la **honestidad empírica**: en vez de vender una estrategia ganadora, el trabajo contrasta la significación de sus resultados y explica cuándo ayuda la optimización —y cuándo, que es lo más habitual, el error de estimación impide distinguirla de una diversificación ingenua.

# 3

## Marco teórico financiero

Este capítulo presenta los fundamentos teóricos sobre los que se construye este trabajo. Se comienza con los conceptos de rentabilidad y riesgo, se desarrolla el modelo de selección de carteras de Markowitz y se introducen el ratio de Sharpe y el modelo CAPM como extensiones naturales. La notación que se establece aquí se mantendrá consistente a lo largo de toda la memoria.

### 3.1 Rentabilidad, riesgo y covarianza

#### 3.1.1 Rentabilidad de un activo

Sea  $P_t$  el precio ajustado de un activo financiero en el instante  $t$ . La **rentabilidad simple** entre  $t - 1$  y  $t$  se define como:

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}} = \frac{P_t}{P_{t-1}} - 1. \quad (3.1)$$

En este trabajo se emplea la **rentabilidad logarítmica** (o log-retorno), definida como:

$$r_t = \ln \frac{P_t}{P_{t-1}} = \ln(P_t) - \ln(P_{t-1}). \quad (3.2)$$

La rentabilidad logarítmica tiene dos ventajas para el análisis cuantitativo. Es **aditiva en el tiempo**: la rentabilidad acumulada en  $k$  días es la suma de las diarias,

$$r_{t \rightarrow t+k} = \ln \frac{P_{t+k}}{P_t} = \sum_{j=1}^k r_{t+j}, \quad (3.3)$$

lo que permite agregar a frecuencias mayores con una simple suma —así se pasa de datos diarios a la frecuencia mensual del backtesting—. Y para variaciones pequeñas ( $|R_t| \ll 1$ ) cumple  $r_t \approx R_t$ , con lo que hereda la interpretabilidad de la rentabilidad simple.

### 3.1.2 Riesgo: volatilidad

El **riesgo** de un activo se mide con la **volatilidad**  $\sigma$ , definida como la desviación típica de sus rentabilidades:

$$\sigma = \sqrt{\text{Var}[r]} = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (r_t - \bar{r})^2}, \quad (3.4)$$

donde  $\bar{r} = \frac{1}{T} \sum_{t=1}^T r_t$  es la rentabilidad media muestral. La volatilidad se expresa típicamente en términos anualizados; si  $r$  es una rentabilidad diaria,  $\sigma_{\text{anual}} = \sigma \cdot \sqrt{252}$ , y si  $r$  es mensual,  $\sigma_{\text{anual}} = \sigma \cdot \sqrt{12}$ .

### 3.1.3 Covarianza y correlación

Dados dos activos  $i$  y  $j$ , su **covarianza** mide la tendencia conjunta de sus rentabilidades:

$$\sigma_{ij} = \text{Cov}[r_i, r_j] = \frac{1}{T-1} \sum_{t=1}^T (r_{it} - \bar{r}_i)(r_{jt} - \bar{r}_j). \quad (3.5)$$

La **matriz de covarianza**  $\Sigma = [\sigma_{ij}] \in \mathbb{R}^{n \times n}$  recoge las covarianzas entre todos los pares de activos de un universo de  $n$  títulos. Es simétrica ( $\sigma_{ij} = \sigma_{ji}$ ) y semidefinida positiva ( $\mathbf{x}^T \Sigma \mathbf{x} \geq 0$  para todo  $\mathbf{x} \in \mathbb{R}^n$ ).

La **correlación** normaliza la covarianza al intervalo  $[-1, 1]$ :

$$\rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \sigma_j}, \quad (3.6)$$

donde  $\sigma_i = \sqrt{\sigma_{ii}}$  es la volatilidad del activo  $i$ .

### 3.1.4 El principio de diversificación

La varianza de una cartera con pesos  $\mathbf{w} = (w_1, \dots, w_n)^T$  es:

$$\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w} = \sum_{i=1}^n w_i^2 \sigma_i^2 + \sum_{i=1}^n \sum_{\substack{j=1 \\ j \neq i}}^n w_i w_j \sigma_{ij}. \quad (3.7)$$

El primer sumando recoge las **varianzas propias** de cada activo; el segundo, los **términos de covarianza** entre pares de activos. Es este segundo bloque el que hace que el riesgo de la cartera no sea, en general, la suma ponderada de los riesgos individuales.

En efecto, cuando los activos no están perfectamente correlacionados, la desviación típica de la cartera satisface

$$\sigma_p \leq \sum_{i=1}^n w_i \sigma_i \quad (w_i \geq 0), \quad (3.8)$$

con igualdad si y solo si todas las correlaciones valen 1. Combinar activos imperfectamente correlacionados reduce, por tanto, el riesgo por debajo de la media ponderada de los individuales sin sacrificar rentabilidad esperada: esta es la esencia de la **diversificación** y el punto de partida de Markowitz. Su descomposición en riesgo *diversificable* (idiosincrásico) y *no diversificable* (sistemático) se formaliza con modelos de factores como el CAPM y el APT (Capítulo 5).

## 3.2 Teoría Moderna de Carteras de Markowitz

En su artículo seminal de 1952, Harry Markowitz propuso un marco matemático para construir carteras óptimas a partir de dos criterios contrapuestos: maximizar la rentabilidad esperada y minimizar el riesgo [Markowitz, 1952](#).

### 3.2.1 Rentabilidad y riesgo de una cartera

Sea  $\mathbf{w} \in \mathbb{R}^n$  el vector de pesos de una cartera, donde  $w_i$  representa la fracción de capital invertida en el activo  $i$ . Sea  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T$  el vector de rentabilidades esperadas de los activos, con  $\mu_i = \mathbb{E}[r_i]$ .

La **rentabilidad esperada** de la cartera es la combinación lineal de las rentabilidades esperadas de sus componentes:

$$\mu_p = \mathbb{E}[r_p] = \mathbb{E}\left[\sum_{i=1}^n w_i r_i\right] = \sum_{i=1}^n w_i \mathbb{E}[r_i] = \mathbf{w}^T \boldsymbol{\mu}. \quad (3.9)$$

La **varianza** de la cartera viene dada por la forma cuadrática (3.7), que en notación matricial se escribe:

$$\sigma_p^2 = \text{Var}[r_p] = \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w}. \quad (3.10)$$

### 3.2.2 El problema de optimización media-varianza

Markowitz formula la selección de carteras como un problema de optimización bicriterio: maximizar  $\mu_p$  y minimizar  $\sigma_p^2$ . Esto da lugar a dos formulaciones equivalentes:

1. **Minimizar el riesgo** dada una rentabilidad objetivo  $\mu^*$ :

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w} \\ \text{s.a.} \quad & \mathbf{w}^T \boldsymbol{\mu} \geq \mu^*, \\ & \sum_{i=1}^n w_i = 1. \end{aligned} \quad (3.11)$$

2. **Maximizar la rentabilidad** dado un nivel de riesgo  $\sigma_*$ :

$$\begin{aligned} \max_{\mathbf{w}} \quad & \mathbf{w}^T \boldsymbol{\mu} \\ \text{s.a.} \quad & \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w} \leq \sigma_*^2, \\ & \sum_{i=1}^n w_i = 1. \end{aligned} \quad (3.12)$$

La primera es un **programa cuadrático convexo** (QP); la segunda, un problema con *restricción* cuadrática (QCQP), igualmente convexo. Ambas producen la misma frontera eficiente (Capítulo 4); se usa la primera, más conveniente. Además del presupuesto ( $\sum_i w_i = 1$ ), se imponen dos restricciones por realismo: **long-only** ( $w_i \geq 0$ , sin ventas en corto) y un **tope por activo** ( $w_i \leq w_{\max}$ , típicamente 0,20, que limita la concentración).

### 3.3 Frontera eficiente y cartera tangente

#### 3.3.1 Definición de frontera eficiente

Al resolver el problema (3.11) para distintos valores del objetivo de rentabilidad  $\mu^*$ , se obtiene una familia de carteras óptimas. En el plano  $(\sigma_p, \mu_p)$ , estas carteras describen una curva denominada **frontera eficiente**: para cada nivel de riesgo, la cartera que maximiza la rentabilidad esperada; equivalentemente, para cada nivel de rentabilidad, la cartera que minimiza el riesgo.

Las carteras por debajo de la frontera son **ineficientes** —otra ofrece más rentabilidad al mismo riesgo, o menos riesgo a igual rentabilidad— y las que quedan por encima son **inalcanzables** con el universo y las restricciones dadas.

#### 3.3.2 Cartera de mínima varianza global (GMV)

El extremo izquierdo de la frontera es la **cartera de mínima varianza global** (GMV, por sus siglas en inglés). Se obtiene resolviendo el QP sin restricción de rentabilidad objetivo:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \mathbf{w}^T \Sigma \mathbf{w} \\ \text{s.a.} \quad & \sum_{i=1}^n w_i = 1, \quad \mathbf{w} \geq \mathbf{0}. \end{aligned} \quad (3.13)$$

La GMV es la cartera de menor riesgo posible dentro del universo de activos y no depende de  $\mu$  (solo de  $\Sigma$ ). Esta propiedad la convierte en una referencia especialmente útil: su rendimiento depende exclusivamente de la calidad de la estimación de la matriz de covarianza.

#### 3.3.3 Cartera tangente y máximo ratio de Sharpe

El **ratio de Sharpe** [Sharpe, 1966](#) mide el exceso de rentabilidad por unidad de riesgo:

$$S_p = \frac{\mu_p - r_f}{\sigma_p}, \quad (3.14)$$

donde  $r_f$  es la tasa libre de riesgo (que en este trabajo se toma como  $r_f = 0$  por simplicidad, dado que los tipos de interés de referencia se mantuvieron próximos a cero durante buena parte del período de estudio).

La **cartera tangente** (o de máximo ratio de Sharpe) es el punto de la frontera cuya recta desde el activo libre de riesgo es tangente a ella; según el teorema de separación de Tobin [Tobin, 1958](#), es la combinación óptima de activos con riesgo para cualquier inversor que preste o tome prestado al tipo  $r_f$ . Con restricciones de desigualdad no admite forma cerrada y se obtiene numéricamente, barriendo la frontera y tomando el punto de mayor Sharpe —el enfoque de nuestra implementación.

### 3.4 Capital Market Line y CAPM

#### 3.4.1 Capital Market Line (CML)

En el plano  $(\sigma_p, \mu_p)$ , la **línea del mercado de capitales** (CML) es la semirrecta que parte de  $(0, r_f)$  y es tangente a la frontera eficiente en la cartera tangente  $T =$



$(\sigma_T, \mu_T)$ . Su ecuación es:

$$\mu_p = r_f + \frac{\mu_T - r_f}{\sigma_T} \sigma_p. \quad (3.15)$$

Cualquier punto sobre la CML representa una combinación del activo libre de riesgo y la cartera tangente  $T$ , y domina a cualquier cartera sobre la frontera eficiente original (excepto en el punto de tangencia).

### 3.4.2 Capital Asset Pricing Model (CAPM)

El CAPM, desarrollado por Sharpe [Sharpe, 1964](#) y Lintner [Lintner, 1965](#), extiende el modelo de Markowitz introduciendo el concepto de equilibrio de mercado. Su ecuación fundamental es:

$$\mathbb{E}[r_i] - r_f = \beta_i (\mathbb{E}[r_m] - r_f), \quad (3.16)$$

donde  $\beta_i = \text{Cov}[r_i, r_m] / \text{Var}[r_m]$  mide la sensibilidad del activo  $i$  a los movimientos del mercado, y  $r_m$  es la rentabilidad de la cartera de mercado.

El CAPM predice que, en equilibrio, toda la rentabilidad esperada de un activo se explica por su exposición al riesgo sistemático (no diversificable), medido por  $\beta_i$ . El riesgo idiosincrásico no se remunera porque puede eliminarse diversificando.

Aunque el CAPM es un modelo de equilibrio y el de Markowitz uno normativo, comparten la estructura media-varianza. Su conexión es relevante aquí en dos sentidos: justifica usar el SPY (proxy de la cartera de mercado) como baseline, y la estimación de  $\Sigma$  mediante PCA y factores (Capítulo 5) responde a la misma idea de separar el riesgo sistemático del idiosincrásico.

## 3.5 Síntesis y conexión con el resto del trabajo

El modelo de Markowitz proporciona un marco riguroso para la selección de carteras, pero su implementación requiere estimar  $\mu$  y  $\Sigma$ , y la calidad de esas estimaciones determina el rendimiento out-of-sample. De ello se ocupan los capítulos siguientes: el Capítulo 4 desarrolla la formulación del QP y sus condiciones de optimalidad; el Capítulo 5, el error de estimación y los estimadores robustos de  $\Sigma$  (shrinkage, PCA); y el Capítulo 6, el uso de Machine Learning para estimar  $\mu$ .

# 4

## Formulación matemática del problema

Este capítulo es el núcleo matemático del trabajo. Se formula el modelo de selección de carteras de Markowitz como un problema de optimización cuadrática convexa (QP), se analizan sus condiciones de optimalidad de Karush-Kuhn-Tucker (KKT), se estudia la dualidad y se presenta la solución analítica de la frontera eficiente para el caso sin restricciones de desigualdad (cuya derivación completa se recoge en el Apéndice A). La notación y los resultados aquí desarrollados son la base sobre la que se construye la implementación computacional del Capítulo 7.

### 4.1 El modelo media-varianza como problema de optimización

#### 4.1.1 Notación

Sea un universo de  $n$  activos financieros. Se denota:

- $\mathbf{w} = (w_1, \dots, w_n)^T \in \mathbb{R}^n$ : vector de pesos de la cartera.
- $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T \in \mathbb{R}^n$ : vector de rentabilidades esperadas, donde  $\mu_i = \mathbb{E}[r_i]$ .
- $\boldsymbol{\Sigma} = [\sigma_{ij}] \in \mathbb{R}^{n \times n}$ : matriz de covarianza, simétrica y semidefinida positiva:  $\boldsymbol{\Sigma} \geq 0$ .
- $\mathbf{1} = (1, \dots, 1)^T \in \mathbb{R}^n$ .

#### 4.1.2 Formulación primal

El problema de Markowitz en su forma estándar (minimizar riesgo sujeto a una rentabilidad objetivo) se escribe:

$$\begin{aligned} \min_{\mathbf{w} \in \mathbb{R}^n} \quad & f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w} \\ \text{sujeto a} \quad & \mathbf{w}^T \boldsymbol{\mu} \geq \mu^*, \\ & \mathbf{1}^T \mathbf{w} = 1, \\ & w_i \geq 0, \quad i = 1, \dots, n, \\ & w_i \leq w_{\max}, \quad i = 1, \dots, n. \end{aligned} \tag{4.1}$$

El factor  $\frac{1}{2}$  en la función objetivo es puramente algebraico: simplifica las expresiones de las derivadas sin alterar el óptimo. La primera restricción exige que la cartera alcance al menos una rentabilidad esperada  $\mu^*$ . La segunda es la restricción de presupuesto. Las dos últimas son restricciones de desigualdad que acotan inferior y superiormente cada peso.

El caso particular en que se omite la restricción de rentabilidad objetivo ( $\mathbf{w}^T \boldsymbol{\mu} \geq \mu^*$ ) se conoce como **cartera de mínima varianza global** (GMV):

$$\min_{\mathbf{w}} \frac{1}{2} \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w} \quad \text{s.a.} \quad \mathbf{1}^T \mathbf{w} = 1, \quad \mathbf{w} \geq \mathbf{0}, \quad \mathbf{w} \leq w_{\max} \mathbf{1}. \quad (4.2)$$

## 4.2 Convexidad del problema cuadrático

Un problema de optimización es **convexo** si la función objetivo es convexa y la región factible es un conjunto convexo. Esta propiedad es crucial: garantiza que todo mínimo local es también global y que las condiciones KKT son necesarias y suficientes para la optimalidad (junto con la condición de Slater, Sección 4.4) [Boyd y Vandenberghe, 2004](#). A continuación se comprueba que el problema de Markowitz cumple ambas condiciones.

### 4.2.1 Convexidad de la función objetivo

La función objetivo es la forma cuadrática:

$$f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w}. \quad (4.3)$$

Su matriz hessiana es  $\nabla^2 f(\mathbf{w}) = \boldsymbol{\Sigma}$ . Dado que  $\boldsymbol{\Sigma}$  es una matriz de covarianza, es semidefinida positiva por construcción:

$$\mathbf{x}^T \boldsymbol{\Sigma} \mathbf{x} = \text{Var}[\mathbf{x}^T \mathbf{r}] \geq 0, \quad \forall \mathbf{x} \in \mathbb{R}^n. \quad (4.4)$$

Por tanto,  $f$  es una función convexa ( $\boldsymbol{\Sigma} \geq 0$  implica convexidad; si  $\boldsymbol{\Sigma} > 0$ , la función es estrictamente convexa). En la práctica, con  $T > n$  observaciones y activos no redundantes,  $\boldsymbol{\Sigma}$  es definida positiva y la solución es única.

### 4.2.2 Convexidad de la región factible

La región factible  $\mathcal{F}$  está definida por:

$$\mathcal{F} = \left\{ \mathbf{w} \in \mathbb{R}^n \left| \begin{array}{l} \mathbf{1}^T \mathbf{w} = 1, \\ \mathbf{w}^T \boldsymbol{\mu} \geq \mu^*, \\ 0 \leq w_i \leq w_{\max}, \quad i = 1, \dots, n \end{array} \right. \right\}. \quad (4.5)$$

$\mathcal{F}$  es intersección de conjuntos convexos —el hiperplano  $\mathbf{1}^T \mathbf{w} = 1$ , el semiespacio  $\mathbf{w}^T \boldsymbol{\mu} \geq \mu^*$  y el hiperrectángulo  $0 \leq w_i \leq w_{\max}$ —, luego es convexa; y es compacta (cerrada y acotada), de modo que el teorema de Weierstrass garantiza la existencia de un mínimo global. Al ser convexos tanto el objetivo como la región, el problema (4.1) es un **programa cuadrático convexo** (QP), y el óptimo que halla un solver estándar (cvxpy) es el óptimo global.

Geométricamente,  $\mathcal{F}$  es un politopo convexo: la intersección del  $(n-1)$ -simplex  $\{\mathbf{w} \geq \mathbf{0} \mid \mathbf{1}^T \mathbf{w} = 1\}$  con el hipercubo  $[0, w_{\max}]^n$  y el semiespacio  $\mathbf{w}^T \boldsymbol{\mu} \geq \mu^*$ . Los topes  $w_i \leq w_{\max}$  truncan los vértices del simplex —las carteras concentradas en un

solo activo—, lo que hace la región más realista pero impide una solución analítica cerrada; y si  $\mu^*$  es demasiado grande,  $\mathcal{F}$  puede quedar vacía y el problema resulta infactible.

### 4.3 Condiciones de Karush-Kuhn-Tucker (KKT)

Las condiciones KKT caracterizan el óptimo de un problema con restricciones de igualdad y desigualdad a través de su Lagrangiano; su forma general se recuerda en el Apéndice B.1. A continuación se particularizan al QP de Markowitz.

Escribiendo el QP (4.1) en la forma estándar general —con función objetivo  $f(\mathbf{w}) = \frac{1}{2}\mathbf{w}^T \Sigma \mathbf{w}$ , las desigualdades  $g_i \leq 0$  (long-only, tope por activo y rentabilidad objetivo) y la igualdad  $\mathbf{1}^T \mathbf{w} = 1$ — e introduciendo los multiplicadores  $\alpha_i, \beta_i \geq 0$  (cotas por activo),  $\gamma \geq 0$  (rentabilidad) y  $\lambda \in \mathbb{R}$  (presupuesto), el Lagrangiano resultante (detallado en el Apéndice B.2) da lugar a las siguientes **condiciones KKT** para el óptimo  $\mathbf{w}^*$ :

#### 1. Estacionariedad

El gradiente del Lagrangiano respecto a  $\mathbf{w}$  se anula en el óptimo:

$$\nabla_{\mathbf{w}} \mathcal{L} = \Sigma \mathbf{w}^* - \boldsymbol{\alpha} + \boldsymbol{\beta} - \gamma \boldsymbol{\mu} - \lambda \mathbf{1} = \mathbf{0}. \quad (4.6)$$

Esta ecuación tiene una lectura financiera directa: en el óptimo, el riesgo adicional que aporta cada activo ( $[\Sigma \mathbf{w}^*]_i$ ) se equilibra con su beneficio en rentabilidad ( $\gamma \mu_i$ ), ajustado por los multiplicadores de las restricciones activas y el precio del presupuesto  $\lambda$ .

#### 2. Factibilidad primal y dual

El punto  $\mathbf{w}^*$  satisface todas las restricciones y los multiplicadores de las desigualdades son no negativos:

$$\mathbf{1}^T \mathbf{w}^* = 1, \quad 0 \leq w_i^* \leq w_{\max}, \quad \mathbf{w}^{*T} \boldsymbol{\mu} \geq \mu^*; \quad \alpha_i, \beta_i, \gamma \geq 0. \quad (4.7)$$

#### 3. Holgura complementaria

Para cada restricción de desigualdad, o bien la restricción está activa (se cumple con igualdad) o bien su multiplicador es cero:

$$\alpha_i w_i^* = 0, \quad i = 1, \dots, n, \quad (4.8)$$

$$\beta_i (w_i^* - w_{\max}) = 0, \quad i = 1, \dots, n, \quad (4.9)$$

$$\gamma (\mu^* - \mathbf{w}^{*T} \boldsymbol{\mu}) = 0. \quad (4.10)$$

La holgura complementaria admite una interpretación económica clara según el peso del activo en el óptimo: si  $0 < w_i^* < w_{\max}$ , entonces  $\alpha_i = \beta_i = 0$  y la estacionariedad se reduce a  $[\Sigma \mathbf{w}^*]_i = \gamma \mu_i + \lambda$  (el coste marginal de riesgo iguala al beneficio marginal de rentabilidad); si  $w_i^* = 0$ , el activo queda fuera porque su contribución al riesgo supera a la de rentabilidad; y si  $w_i^* = w_{\max}$ , está en su tope porque su rentabilidad justifica asumir más riesgo del que permiten las restricciones.

La implementación verifica explícitamente que la solución de `cvxpy` satisface estas condiciones: el test `test_condiciones_kkt` recupera los multiplicadores a partir

de la solución numérica y comprueba las cuatro condiciones con tolerancia  $10^{-4}$ , una validación independiente del solver.

## 4.4 Dualidad e interpretación económica

### 4.4.1 El problema dual

Asociado al problema primal (4.1) existe un **problema dual** que proporciona una cota inferior del valor óptimo primal. Si el problema convexo satisface la condición de Slater (existe un punto estrictamente factible), la **dualidad fuerte** garantiza que los valores óptimos primal y dual coinciden [Boyd y Vandenberghe, 2004](#).

En nuestro QP, Slater se cumple si  $n \cdot w_{\max} > 1$  (los topes son compatibles con el presupuesto) y  $\mu^*$  es estrictamente menor que la máxima rentabilidad esperada alcanzable respetando los topes; bajo esas condiciones existe un punto estrictamente interior a la región factible.

### 4.4.2 Interpretación de los multiplicadores

Los multiplicadores de KKT se interpretan como **precios sombra**: el precio sombra de una restricción indica cuánto bajaría la varianza mínima de la cartera si esa restricción se relajara en una unidad. Dicho de otro modo, mide lo que “cuesta” esa restricción en el óptimo. En nuestro problema:

- $\lambda$  (presupuesto): cuánto cambiaría el riesgo si el capital a invertir fuera algo mayor o menor.
- $\gamma$  (rentabilidad objetivo): cuánto bajaría el riesgo si se exigiera un poco menos de rentabilidad.
- $\alpha_i$  (cota  $w_i \geq 0$ ): si es positivo, permitir una pequeña posición corta en el activo  $i$  reduciría el riesgo.
- $\beta_i$  (tope  $w_i \leq w_{\max}$ ): si es positivo, dejar invertir algo más del tope en el activo  $i$  reduciría el riesgo.

## 4.5 Solución analítica de la frontera eficiente

Cuando se eliminan las restricciones de desigualdad ( $w_i \geq 0$  y  $w_i \leq w_{\max}$ ) y se supone  $\Sigma > 0$ , el problema admite una solución analítica cerrada, uno de los resultados clásicos de la teoría de carteras [Merton, 1972](#). La frontera de mínima varianza es una hipérbola en el plano  $(\sigma_p, \mu_p)$ ,

$$\sigma_p^2 = \frac{A\mu_p^2 - 2B\mu_p + C}{\Delta}, \quad A = \mathbf{1}^T \Sigma^{-1} \mathbf{1}, \quad B = \mathbf{1}^T \Sigma^{-1} \boldsymbol{\mu}, \quad C = \boldsymbol{\mu}^T \Sigma^{-1} \boldsymbol{\mu},$$

con  $\Delta = AC - B^2 > 0$  (positivo por Cauchy-Schwarz siempre que  $\boldsymbol{\mu}$  y  $\mathbf{1}$  sean linealmente independientes). Su vértice es la cartera de mínima varianza global (GMV), con  $\mu_{\text{GMV}} = B/A$ , y el punto de tangencia con una recta por el origen da la cartera de máximo ratio de Sharpe:

$$\mathbf{w}_{\text{GMV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}, \quad \mathbf{w}_T = \frac{\Sigma^{-1} \boldsymbol{\mu}}{\mathbf{1}^T \Sigma^{-1} \boldsymbol{\mu}}.$$

La derivación completa por multiplicadores de Lagrange —con la ecuación de la frontera, las expresiones de la GMV y de la cartera tangente, y su validación numérica frente a `cvxpy`— se recoge en el Apéndice [A](#).

## 4.6 Del caso analítico al caso con restricciones

Cuando se añaden las restricciones  $w_i \geq 0$  y  $w_i \leq w_{\max}$ , la solución deja de admitir una expresión cerrada. La frontera eficiente ya no es una hipérbola perfecta, sino una curva suave definida a trozos por los puntos donde las restricciones se activan o desactivan, y la resolución pasa a ser numérica.

Sin embargo, las propiedades cualitativas se conservan:

- El problema sigue siendo convexo (la región factible es un subconjunto convexo del simplex).
- La solución es única si  $\Sigma > 0$ .
- Las condiciones KKT siguen caracterizando completamente el óptimo.
- La frontera eficiente es creciente y cóncava en el espacio  $(\sigma_p, \mu_p)$ .

Esto justifica el uso de `cvxpy` como solver exacto: la convexidad garantiza optimalidad global, y las condiciones KKT proporcionan una herramienta de verificación independiente del solver.

# 5

## Limitaciones del modelo clásico

El modelo de Markowitz formulado en el Capítulo 4 es matemáticamente impecable: dado un vector de rentabilidades esperadas  $\mu$  y una matriz de covarianza  $\Sigma$ , el QP convexo produce la cartera óptima. Sin embargo, en la práctica  $\mu$  y  $\Sigma$  no se conocen: deben estimarse a partir de datos históricos. Este capítulo analiza las consecuencias del error de estimación, presenta dos enfoques para mejorar la estimación de  $\Sigma$  (shrinkage de Ledoit-Wolf y modelos de factores basados en PCA) y motiva el uso de Machine Learning para estimar  $\mu$ .

### 5.1 El error de estimación y sus consecuencias

#### 5.1.1 Dimensionalidad y escasez de datos

El modelo de Markowitz requiere estimar  $n$  rentabilidades esperadas y  $n(n+1)/2$  covarianzas distintas. Para nuestro universo de  $n = 30$  activos, esto supone  $30 + 30 \times 31/2 = 495$  parámetros. Con una ventana de estimación de 3 años de datos mensuales ( $T = 36$  observaciones), el cociente  $n/T \approx 0,83$  es demasiado alto: los 495 parámetros se estiman con solo  $30 \times 36 = 1080$  datos, poco más de dos datos por parámetro.

En estas condiciones, el estimador muestral de  $\Sigma$ , aunque insesgado, tiene una varianza muy elevada. Los autovalores pequeños de la matriz muestral están sistemáticamente infraestimados y los grandes, sobreestimados [Ledoit y Wolf, 2004](#). Esto tiene consecuencias directas sobre la optimización: el QP explota estos errores, asignando pesos desproporcionados a activos cuya covarianza está mal estimada.

#### 5.1.2 El problema de la estimación de $\mu$

Si estimar  $\Sigma$  es difícil, estimar  $\mu$  lo es aún más. La rentabilidad esperada de un activo es muy ruidosa: la desviación típica de la media muestral es  $\sigma/\sqrt{T}$ , que con  $\sigma \approx 0,05$  mensual y  $T = 36$  meses da aproximadamente 0,0083, comparable a la propia media muestral para muchos activos. En otras palabras, la incertidumbre en la estimación de  $\mu$  es del mismo orden de magnitud que el propio parámetro.

Merton [Merton, 1980](#) demostró que, mientras la varianza puede estimarse con precisión creciente al aumentar la frecuencia de observación, la precisión de la estimación de la media depende únicamente del horizonte temporal total, no de la frecuencia. Con 15 años de datos, la media anualizada tiene un error estándar de  $\sigma_{\text{anual}}/\sqrt{15} = 0,05 \cdot \sqrt{12}/\sqrt{15} \approx 0,045$ : unos 4,5 puntos porcentuales de incertidumbre, del mismo orden que la propia rentabilidad que se quiere estimar.

Este es el punto débil que el Machine Learning puede ayudar a mitigar: si existe una relación predecible entre las características observables de los activos y sus rentabilidades futuras, un modelo predictivo puede producir una estimación de  $\mu$  más precisa que la simple media histórica (Capítulo 6).

## 5.2 Inestabilidad y concentración de los pesos

### 5.2.1 Demostración empírica

Para ilustrar el problema, comparamos las carteras de mínima varianza (GMV) obtenidas con tres estimadores de  $\Sigma$  sobre la misma ventana de 3 años (enero 2022 – diciembre 2024). Se usa la GMV porque no depende de las rentabilidades esperadas  $\mu$ , sino solo de la covarianza  $\Sigma$ ; así, cualquier diferencia entre las tres carteras se debe únicamente al estimador de  $\Sigma$ . La Tabla 5.1 resume los resultados.

**Cuadro 5.1:** Comparación de carteras GMV según el estimador de  $\Sigma$ . Ventana: 2022–2024 (36 meses).

| Estimador   | Activos > 1 % | HHI   | $\sigma_p$ (mensual) |
|-------------|---------------|-------|----------------------|
| Muestral    | 10            | 0.137 | 3.25 %               |
| Ledoit-Wolf | 14            | 0.099 | 3.12 %               |
| PCA (80 %)  | 11            | 0.130 | 3.28 %               |

El estimador muestral concentra la cartera en solo 10 activos (de 30) con un índice Herfindahl-Hirschman (HHI) de 0,137. El HHI se define como:

$$\text{HHI} = \sum_{i=1}^n w_i^2, \quad (5.1)$$

y toma el valor  $1/n \approx 0,033$  para la cartera equiponderada (máxima diversificación) y 1 para una cartera concentrada en un solo activo.


El estimador de Ledoit-Wolf aumenta la diversificación a 14 activos y reduce el HHI a 0,099, mientras que el estimador PCA se sitúa en una posición intermedia (11 activos, HHI 0,130). La volatilidad es muy similar en los tres casos (3,12 %–3,28 % mensual), lo que sugiere que las diferencias en los pesos no se traducen necesariamente en diferencias grandes de riesgo ex-ante (el riesgo estimado antes de invertir), pero sí pueden afectar la estabilidad temporal y el turnover.

### 5.2.2 Evolución temporal de la concentración

La Figura 5.1 muestra la evolución del HHI a lo largo del tiempo utilizando ventanas móviles de 3 años (una ventana de 36 meses que avanza mes a mes). Se observa que el estimador muestral (azul) produce carteras sistemáticamente más concentradas y con mayor variabilidad en el nivel de concentración a lo largo del



tiempo. El estimador de Ledoit-Wolf (naranja) mantiene un HHI siempre más bajo y más estable, mientras que el estimador PCA (verde) presenta un comportamiento intermedio.



**Figura 5.1:** Evolución del índice Herfindahl-Hirschman (HHI) de la cartera GMV con ventanas móviles de 36 meses. La línea gris discontinua marca el HHI de la cartera equiponderada ( $1/30 \approx 0,033$ ).

La inestabilidad de los pesos provoca dos problemas. El primero es un **turnover** elevado: si los pesos óptimos cambian mucho de un mes a otro, hay que comprar y vender activos con frecuencia, y esas comisiones reducen la rentabilidad final. El segundo es la **concentración**: la cartera acaba invertida en pocos activos, justo lo contrario de diversificar, y así asume el riesgo particular de esos títulos, un riesgo que el mercado no remunera porque podría haberse eliminado repartiendo mejor la inversión.

## 5.3 Estimación robusta de la covarianza: shrinkage de Ledoit-Wolf

### 5.3.1 Fundamento teórico

La idea del *shrinkage* es sencilla: en lugar de fiarse por completo de la matriz muestral (precisa en promedio, pero muy ruidosa), se mezcla con una matriz simple y estable, y se toma un punto intermedio. Formalmente, el *shrinkage* es una técnica de regularización que contrae el estimador muestral hacia un estimador estructurado (el *target*), reduciendo el error cuadrático medio esperado a cambio de introducir un pequeño sesgo. Ledoit y Wolf [Ledoit y Wolf, 2004](#) propusieron un estimador de covarianza que es combinación convexa (una media ponderada) del estimador muestral  $\Sigma_{\text{muestral}}$  y un target  $\Sigma_{\text{target}}$ :

$$\Sigma_{\text{LW}} = (1 - \delta) \Sigma_{\text{muestral}} + \delta \Sigma_{\text{target}}, \quad (5.2)$$

donde  $\delta \in [0, 1]$  es la intensidad de shrinkage, calculada analíticamente para minimizar el error cuadrático medio esperado asintóticamente.

El target por defecto en `scikit-learn` (y en nuestra implementación) es una **identidad escalada**: una matriz diagonal cuyos elementos valen todos la varianza media de los activos, con correlaciones nulas fuera de la diagonal,

$$[\Sigma_{\text{target}}]_{ij} = \begin{cases} \bar{\sigma}^2 & \text{si } i = j, \\ 0 & \text{si } i \neq j, \end{cases} \quad \bar{\sigma}^2 = \frac{1}{n} \sum_{k=1}^n \sigma_{kk}^{\text{muestral}}. \quad (5.3)$$


Es un target muy bien condicionado (todos sus autovalores valen  $\bar{\sigma}^2$ ), y al mezclar-

lo con la matriz muestral se atenúan los autovalores extremos y las correlaciones espurias.

### 5.3.2 Efecto sobre la cartera

El efecto del shrinkage sobre los pesos de la cartera GMV se aprecia en la Tabla 5.1: la cartera Ledoit-Wolf es la más diversificada de las tres. Esto se debe a que el shrinkage contrae los autovalores hacia su media: baja los más grandes y, sobre todo, sube los más pequeños, que son los que hacen inestable a  $\Sigma^{-1}$  y los que el QP explotaría para concentrar los pesos.

La Figura 5.2 compara visualmente la distribución de pesos obtenida con cada estimador.



**Figura 5.2:** Pesos de la cartera GMV según el estimador de  $\Sigma$  (solo activos con peso  $> 2\%$  en al menos un estimador).


## 5.4 Covarianza basada en PCA y modelos de factores

La idea es que casi todo lo que mueve a los activos a la vez se debe a unos pocos factores comunes, como el mercado en su conjunto o los sectores; el PCA identifica esos factores y separa esa estructura común del ruido propio de cada activo. La matriz de covarianza muestral admite una descomposición espectral  $\Sigma = \sum_{i=1}^n \lambda_i \mathbf{v}_i \mathbf{v}_i^T$ , con autovalores  $\lambda_1 \geq \dots \geq \lambda_n \geq 0$ , cada uno la varianza explicada por su componente principal. El estimador PCA retiene solo los  $k$  primeros componentes (los factores comunes), descarta el resto como ruido y conserva la varianza específica de cada activo; su construcción detallada se recoge en el Apéndice B.3.

### 5.4.1 Selección del número de factores

La Figura 5.3 muestra los autovalores de la matriz de covarianza muestral y la varianza explicada acumulada para la ventana 2022–2024.

El primer componente principal explica el 44,5 % de la varianza total; con 7 componentes se alcanza el 80 % y con 11 componentes el 90 %. Esto indica que la mayor parte de la variabilidad de las rentabilidades de los 30 activos puede capturarse con un número reducido de factores comunes, lo que justifica el uso de un modelo de factores para la estimación de la covarianza.



**Figura 5.3:** Descomposición espectral de la covarianza muestral. Barras: autovalores (eje izquierdo). Línea: varianza explicada acumulada (eje derecho).

#### 5.4.2 Conexión con la Arbitrage Pricing Theory (APT)

La *Arbitrage Pricing Theory* (APT) de Ross [Ross, 1976](#) sostiene que las rentabilidades de los activos dependen de unos pocos factores de riesgo comunes y de una parte propia de cada activo. La conexión con lo anterior es directa: si se toman como factores los  $k$  primeros componentes principales, el estimador PCA coincide exactamente con ese modelo de factores (la equivalencia se demuestra en el Apéndice B.3). Dicho de otro modo, los componentes principales de la covarianza actúan como los factores de riesgo de la teoría financiera. Esta correspondencia conecta el enfoque puramente estadístico (la descomposición espectral) con la teoría financiera de factores, y es uno de los puntos metodológicamente más relevantes de este trabajo.

### 5.5 Síntesis: del error de estimación a la necesidad de Machine Learning

La estimación de  $\Sigma$  puede mejorarse con regularización (shrinkage) o reducción de dimensionalidad (PCA), pero la de  $\mu$  sigue siendo el punto débil del modelo. De hecho, la Tabla 5.1 muestra que los tres estimadores de  $\Sigma$  dan volatilidades muy parecidas con pesos muy distintos: la elección del estimador afecta más a la composición de la cartera que a su riesgo ex-ante. La rentabilidad realizada, en cambio, depende sobre todo de  $\mu$ , el parámetro más difícil de estimar. De ahí que el Capítulo 6 recurra al Machine Learning para predecirlo: si se estima mejor  $\mu$ , se puede aspirar a carteras con rentabilidad out-of-sample superior a las estrategias pasivas de referencia.

# 6

## Machine Learning para la predicción de $\mu$

El Capítulo 5 demostró que la estimación de  $\mu$  es el punto más débil del modelo de Markowitz: la media muestral tiene un error estándar comparable al propio parámetro, y ningún estimador de  $\Sigma$  puede compensar una mala estimación de las rentabilidades esperadas. Este capítulo explora si las técnicas de Machine Learning pueden mejorar la estimación de  $\mu$  explotando relaciones predecibles entre las características observables de los activos y sus rentabilidades futuras.

### 6.1 Planteamiento del problema predictivo

#### 6.1.1 ¿Por qué Machine Learning?

La estimación tradicional de  $\mu$  como media histórica asume implícitamente que las rentabilidades son independientes e idénticamente distribuidas (i.i.d.). Si esta hipótesis fuera cierta, la media muestral sería el mejor estimador lineal insesgado de  $\mu_i$ . Sin embargo, existe abundante evidencia empírica de que las rentabilidades no son i.i.d.: presentan **autocorrelación** a corto plazo (momentum, reversión a la media), dependencia de la **volatilidad** (clustering) y sensibilidad a **factores de riesgo** comunes [Cont, 2001](#).

Si existe una función  $f$  que relaciona características observables  $\mathbf{x}_{i,t}$  del activo  $i$  en el instante  $t$  con su rentabilidad futura  $r_{i,t+1}$ ,

$$r_{i,t+1} = f(\mathbf{x}_{i,t}) + \varepsilon_{i,t+1}, \quad (6.1)$$

entonces un modelo de ML puede aproximar  $f$  a partir de datos históricos, produciendo una estimación de  $\mu_{i,t+1} = \mathbb{E}[r_{i,t+1} \mid \mathbf{x}_{i,t}]$  potencialmente más precisa que la media incondicional.

La clave está en que el modelo aprende de **todos los activos** simultáneamente (o al menos comparte estructura entre ellos), lo que mitiga la escasez de datos por activo: en lugar de estimar una media por activo con 36 observaciones, el modelo estima una función  $f$  con  $30 \times 36 = 1080$  observaciones, reduciendo la varianza del estimador.

### 6.1.2 Configuración del problema

Para cada activo  $i \in \{1, \dots, n\}$  y cada mes  $t$ , definimos:

- **Target:**  $y_{i,t} = r_{i,t+1}$ , la rentabilidad logarítmica del activo  $i$  en el mes  $t + 1$ .
- **Features:**  $\mathbf{x}_{i,t} \in \mathbb{R}^p$ , un vector de  $p$  características del activo  $i$  calculadas exclusivamente con información disponible hasta el mes  $t$  (inclusive).

El modelo se entrena de forma **agrupada** (*pooled*): se estima una única función  $f$  común a todos los activos, apilando las observaciones de los  $n$  activos de la ventana. Así cada ajuste dispone de  $n \times 36$  observaciones en lugar de 36, lo que reduce drásticamente la varianza del estimador; las predicciones siguen siendo individualizadas porque cada activo entra con sus propias features  $\mathbf{x}_{i,t}$ .

## 6.2 Ingeniería de características (features)

La selección de features está guiada por la literatura sobre predictibilidad de rentabilidades [Gu et al., 2020](#) y por la restricción fundamental de este trabajo: solo se utilizan datos de precio (no fundamentales), ya que el objetivo es un modelo puramente técnico que pueda automatizarse sin depender de fuentes de datos externas.

### 6.2.1 Features basadas en rentabilidades pasadas

- **Rezagos simples:**  $r_{i,t}, r_{i,t-1}, r_{i,t-2}$ . Capturan efectos de autocorrelación a muy corto plazo (reversión o continuación).
- **Momentum:** rentabilidad acumulada en los últimos 3, 6 y 12 meses:

$$\text{mom}_k(i, t) = \sum_{j=0}^{k-1} r_{i,t-j}, \quad k \in \{3, 6, 12\}. \quad (6.2)$$

El momentum a 12 meses es uno de los factores más robustos en la literatura de *cross-section* de rentabilidades [Jegadeesh y Titman, 1993](#).

- **Volatilidad realizada:** desviación típica de las rentabilidades de los últimos 12 meses,  $\sigma_{i,t}^{(12)}$ .
- **Beta al mercado:** pendiente de la regresión de  $r_i$  sobre  $r_m$  (SPY) en ventana de 36 meses,  $\beta_{i,t} = \text{Cov}_{36m}(r_i, r_m) / \text{Var}_{36m}(r_m)$ .

### 6.2.2 Features del mercado

Además de las características propias de cada activo, se incluyen features que capturan el contexto de mercado:

- **Rezagos del mercado:**  $r_{m,t}, r_{m,t-1}$  (rentabilidad del SPY).
- **Volatilidad del mercado:**  $\sigma_{m,t}^{(12)}$ , desviación típica del SPY en 12 meses.

En total, el vector de features tiene dimensión  $p = 11$ . La Tabla [6.1](#) resume las features utilizadas.

**Cuadro 6.1:** Features utilizadas para la predicción de  $r_{i,t+1}$ .

| Feature                | Descripción                              |
|------------------------|------------------------------------------|
| r_lag1, r_lag2, r_lag3 | Rezagos del activo ( $t, t - 1, t - 2$ ) |
| mom3, mom6, mom12      | Momentum a 3, 6 y 12 meses               |
| vol12                  | Volatilidad realizada a 12 meses         |
| beta_36m               | Beta rolling al SPY (36 meses)           |
| r_mkt_lag1, r_mkt_lag2 | Rezagos del SPY                          |
| r_mkt_vol12            | Volatilidad del SPY a 12 meses           |

## 6.3 Modelos de Machine Learning

Se implementan tres modelos que representan distintos compromisos entre sesgo y varianza, flexibilidad e interpretabilidad.

### 6.3.1 Ridge (regularización L2)

Ridge [Hoerl y Kennard, 1970](#) es una regresión lineal con penalización en la norma  $\ell_2$  de los coeficientes:

$$\hat{\beta}_{\text{Ridge}} = \arg \min_{\beta} \left\{ \sum_{i,t} (y_{i,t} - \mathbf{x}_{i,t}^T \beta)^2 + \alpha \sum_{j=1}^p \beta_j^2 \right\}, \quad (6.3)$$

donde la primera suma recorre las observaciones apiladas de todos los activos (la muestra agrupada de la Sección 6.1.2).

La penalización  $\ell_2$  contrae los coeficientes hacia cero sin anularlos: reduce la varianza del estimador a cambio de un pequeño sesgo, y es adecuada cuando muchas features tienen poder predictivo débil pero no nulo o están muy correlacionadas entre sí. En ese caso, una regresión sin penalizar daría coeficientes muy grandes e inestables (la matriz  $\mathbf{X}^T \mathbf{X}$  queda mal condicionada, casi singular); la penalización de Ridge los estabiliza. El hiperparámetro  $\alpha$  —de 0 (mínimos cuadrados ordinarios) a  $\infty$  (todos los coeficientes nulos)— se selecciona por validación cruzada temporal (*TimeSeriesSplit*) en 10 valores entre  $10^{-3}$  y  $10^2$ . Como el entrenamiento es agrupado sobre activos de escalas heterogéneas, las features se estandarizan (media 0, varianza 1) usando solo la muestra de entrenamiento.

### 6.3.2 Lasso (regularización L1)

Lasso [Tibshirani, 1996](#) sustituye la penalización  $\ell_2$  por  $\ell_1$ :

$$\hat{\beta}_{\text{Lasso}} = \arg \min_{\beta} \left\{ \sum_{i,t} (y_{i,t} - \mathbf{x}_{i,t}^T \beta)^2 + \alpha \sum_{j=1}^p |\beta_j| \right\}. \quad (6.4)$$

La norma  $\ell_1$  produce soluciones **sparse** (muchos coeficientes exactamente cero): Lasso hace selección automática de features y es más interpretable que Ridge, a costa de más inestabilidad con features muy correlacionadas [Zou y Hastie, 2005](#). Como en Ridge, las features se estandarizan y  $\alpha$  se elige por validación cruzada temporal en el mismo rango.

### 6.3.3 Random Forest

Random Forest es un método no paramétrico basado en un *ensemble* de árboles de decisión [Breiman, 2001](#). Cada árbol particiona recursivamente el espacio de features para minimizar el error cuadrático medio en cada nodo, y el bosque promedia las predicciones de todos los árboles.

Sus principales ventajas aquí son que captura relaciones no lineales e interacciones entre features sin especificarlas, es robusto a outliers y a features irrelevantes, y el promediado sobre muchos árboles (100 en la implementación) reduce la varianza sin aumentar el sesgo.

Para evitar el sobreajuste se limitan la profundidad máxima de cada árbol a 3 y el número mínimo de muestras por hoja a 5. Estos hiperparámetros, junto con el número de árboles (100), se mantienen fijos para todo el backtesting. A diferencia de los modelos lineales, Random Forest no requiere estandarizar las features, al ser invariante a transformaciones monótonas de cada variable.

## 6.4 Validación temporal (walk-forward)

### 6.4.1 El peligro del look-ahead

En la predicción de series temporales financieras, la validación cruzada estándar (aleatoria) es metodológicamente incorrecta: al barajar las observaciones, se rompe la estructura temporal y el modelo podría entrenarse con datos del futuro para predecir el pasado. Esto produce estimaciones irrealmente optimistas del rendimiento predictivo y, lo que es más grave, contamina la selección de hiperparámetros.

Por esta razón, toda la validación se realiza en régimen walk-forward: en cada mes  $t$ , el modelo solo puede acceder a datos hasta  $t$  para entrenar, validar hiperparámetros y predecir.

### 6.4.2 Protocolo de backtesting

En cada mes  $t$ , el modelo se entrena solo con datos hasta  $t$  (ventana de 36 meses), predice  $\hat{\mu}_{i,t+1}$  para cada activo a partir de sus features de  $t$ , y esas predicciones —junto con  $\hat{\Sigma}$ — alimentan la optimización de la cartera de máximo Sharpe, cuya rentabilidad se evalúa en  $t + 1$ . El ciclo se repite 143 veces (enero 2013 – diciembre 2024). El Capítulo 7 detalla el protocolo completo y las medidas que se toman para evitar el look-ahead.

### 6.4.3 Métricas de evaluación predictiva

Para evaluar la calidad de las predicciones de  $\mu$ , se calculan las siguientes métricas sobre las predicciones out-of-sample de cada modelo:

- **RMSE** (Root Mean Square Error):  $\sqrt{\frac{1}{nT} \sum_{i,t} (r_{i,t+1} - \hat{\mu}_{i,t})^2}$ .
- **MAE** (Mean Absolute Error):  $\frac{1}{nT} \sum_{i,t} |r_{i,t+1} - \hat{\mu}_{i,t}|$ .
- **$R^2$  out-of-sample**:  $1 - \frac{\sum_{i,t} (r_{i,t+1} - \hat{\mu}_{i,t})^2}{\sum_{i,t} (r_{i,t+1} - \bar{r})^2}$ , donde  $\bar{r}$  es la media histórica. Un  $R^2$  positivo indica que el modelo ML mejora sobre la media histórica.
- **Correlación de Pearson** entre  $\hat{\mu}$  y  $r_{t+1}$  realizada, agregada a nivel de mes.

En finanzas, incluso un  $R^2$  pequeño ( $\approx 0,01-0,05$ ) puede ser económicamente significativo si se traduce en una mejora del ratio de Sharpe de la cartera optimizada.

## 6.5 Conexión con la optimización de carteras

El objetivo no es minimizar el RMSE de  $\hat{\mu}$ , sino maximizar el rendimiento out-of-sample de la cartera: un RMSE bajo no garantiza una buena cartera, y el QP puede beneficiarse más de acertar el *orden* (ranking) de los activos que de minimizar el error cuadrático. Por eso la evaluación definitiva se hace sobre las métricas de cartera (Sharpe, drawdown, turnover) del Capítulo 8, y las predictivas se reportan solo como diagnóstico complementario.

## 6.6 Síntesis

En resumen, este capítulo aborda la principal limitación del modelo clásico —la estimación de  $\mu$ — con un marco de Machine Learning que usa 11 features exclusivamente de precio, tres modelos complementarios (Ridge, Lasso y Random Forest), una validación temporal estricta sin look-ahead y, como métrica final, el rendimiento de la cartera y no el RMSE de la predicción. El Capítulo 7 detalla cómo se integran estos modelos con los estimadores de covarianza del Capítulo 5 en el backtesting walk-forward.



# 7

## Metodología y diseño experimental

Este capítulo describe la metodología completa del estudio: los datos utilizados, el esquema de backtesting walk-forward, las carteras evaluadas y las métricas de rendimiento. El objetivo es que el experimento sea completamente reproducible con los datos y el código proporcionados.

### 7.1 Datos

#### 7.1.1 Universo de activos

El universo de inversión está compuesto por 30 acciones del S&P 500, seleccionadas de modo que cubren los once sectores GICS. La Tabla 7.1 detalla los tickers y sus sectores.

**Cuadro 7.1:** *Universo de 30 activos por sector GICS.*

| Sector               | Tickers                      |
|----------------------|------------------------------|
| Tecnología           | AAPL, MSFT, ORCL, CSCO, INTC |
| Salud                | JNJ, PFE, MRK, UNH           |
| Finanzas             | JPM, GS, AXP, BAC            |
| Consumo discrecional | HD, MCD, NKE                 |
| Consumo básico       | PG, KO, WMT                  |
| Comunicaciones       | VZ, T, DIS                   |
| Energía              | XOM, CVX                     |
| Industriales         | CAT, HON, UPS                |
| Materiales           | FCX                          |
| Utilities            | NEE                          |
| Inmobiliario         | AMT                          |

Como referencia de mercado se utiliza el **SPY** (SPDR S&P 500 ETF Trust), que replica el S&P 500 y no forma parte del universo a optimizar.

#### 7.1.2 Periodo y frecuencia

- **Periodo total:** 1 de enero de 2010 – 31 de diciembre de 2024 (15 años).

- **Datos diarios:** 3.773 días de negociación para 31 tickers (30 acciones + SPY).
- **Frecuencia de trabajo:** mensual. Los retornos logarítmicos diarios se agregan a frecuencia mensual mediante suma:  $r_t^{\text{mensual}} = \sum_{d \in \text{mes}(t)} r_d^{\text{diaria}}$ , propiedad que deriva de la aditividad de los log-retornos (ecuación 3.3).
- **Meses resultantes:** 180 meses (enero 2010 – diciembre 2024).

### 7.1.3 Fuente y preprocesado

Los precios ajustados (cierre) se descargan de **Yahoo Finance** a través de la librería `yfinance` de Python. El preprocesado consiste en:

1. **Cálculo de retornos logarítmicos diarios:**  $r_t = \ln(P_t/P_{t-1})$ .
2. **Limpieza:** eliminación de días sin negociación, *forward-fill* de datos faltantes.
3. **Agregación mensual:** suma de retornos diarios dentro de cada mes natural.

Se reconoce explícitamente la presencia de **sesgo de supervivencia**: el universo está compuesto por constituyentes actuales (2024) del S&P 500, no por los constituyentes históricos. Esto implica que las empresas que quebraron o fueron excluidas del índice durante el periodo de estudio no están representadas. El sesgo tiende a sobreestimar ligeramente las rentabilidades históricas, pero su impacto en un estudio de asignación de activos como este es limitado, ya que el objetivo es comparar metodologías de optimización, no estimar rentabilidades absolutas.

## 7.2 Esquema de backtesting walk-forward

El experimento sigue un protocolo de backtesting walk-forward con rebalanceo mensual, que constituye el estándar metodológico en la literatura de optimización de carteras [DeMiguel et al., 2009](#).

### 7.2.1 Parámetros del backtesting

- **Ventana de estimación:** 36 meses (3 años).
- **Frecuencia de rebalanceo:** mensual.
- **Periodo out-of-sample:** enero 2013 – diciembre 2024 (144 meses, de los cuales se evalúan 143 por el desfase de la predicción).
- **Restricciones:** long-only ( $w_i \geq 0$ ), peso máximo por activo  $w_i \leq 0,20$ , presupuesto  $\sum_i w_i = 1$ .

### 7.2.2 Procedimiento mensual

Para cada mes  $t$  desde enero de 2013 ( $t = 37$ ) hasta noviembre de 2024 ( $t = 179$ ): se toma la ventana de 36 meses ( $t - 35, \dots, t$ ); se estima  $\Sigma$  con uno de los tres estimadores (muestral, Ledoit-Wolf o PCA al 80 % de varianza) y  $\mu$  con uno de los cuatro métodos (media histórica, Ridge, Lasso o RF); se resuelve el QP de mínimo riesgo (ecuación 3.11) barriando el objetivo de rentabilidad  $\mu^*$  y se toma el punto de máximo Sharpe, que da los pesos  $w_t$ ; y se evalúa la rentabilidad realizada  $r_{p,t+1} = w_t^T r_{t+1}$ .

Esquemáticamente, para un total de  $T = 180$  meses:

$$\underbrace{r_2, \dots, r_{37}}_{\text{Train}_1} \rightarrow \underbrace{r_{38}}_{\text{Pred}_1} \quad \underbrace{r_3, \dots, r_{38}}_{\text{Train}_2} \rightarrow \underbrace{r_{39}}_{\text{Pred}_2} \quad \dots \quad \underbrace{r_{144}, \dots, r_{179}}_{\text{Train}_{143}} \rightarrow \underbrace{r_{180}}_{\text{Pred}_{143}}$$

donde  $\text{Train}_k$  es la ventana de 36 meses usada para estimar  $\mu$  y  $\Sigma$  en la iteración  $k$ , y  $\text{Pred}_k$  es el mes out-of-sample cuya rentabilidad  $r_{p,k}$  se evalúa.

### 7.2.3 Prevención del look-ahead

Para evitar el look-ahead se toman las siguientes medidas:

- La estimación de  $\Sigma$  en el mes  $t$  solo utiliza rentabilidades hasta  $t$ .
- Las features para la predicción ML en  $t$  solo utilizan datos hasta  $t$  (ver Capítulo 6).
- La rentabilidad out-of-sample  $r_{p,t+1}$  **no** se utiliza en ningún paso de la optimización para el mes  $t$ .
- La validación cruzada para la selección de hiperparámetros de los modelos ML se realiza con `TimeSeriesSplit`, que respeta el orden cronológico.

## 7.3 Carteras evaluadas

Se evalúan 8 carteras, presentadas en la Tabla 7.2. Las tres primeras corresponden al modelo de Markowitz clásico con distintos estimadores de  $\Sigma$ , las tres siguientes incorporan predicciones ML de  $\mu$ , y las dos últimas son baselines pasivos.

**Cuadro 7.2:** Carteras evaluadas en el experimento.

| Cartera                 | Estimador de $\Sigma$ | Estimador de $\mu$ |
|-------------------------|-----------------------|--------------------|
| Markowitz (muestral)    | Muestral              | Media histórica    |
| Markowitz (Ledoit-Wolf) | Ledoit-Wolf           | Media histórica    |
| Markowitz (PCA)         | PCA (80 % var.)       | Media histórica    |
| Markowitz + Ridge       | Ledoit-Wolf           | Ridge              |
| Markowitz + Lasso       | Ledoit-Wolf           | Lasso              |
| Markowitz + RF          | Ledoit-Wolf           | Random Forest      |
| 1/N (equiponderada)     | –                     | –                  |
| SPY (mercado)           | –                     | –                  |

**Nota sobre la elección de  $\Sigma$  para las estrategias ML:** se utiliza el estimador de Ledoit-Wolf para todas ellas, por ser el más fiable en términos de diversificación y estabilidad (Capítulo 5). Esto permite aislar el efecto de la mejora en  $\mu$  sin que las diferencias en  $\Sigma$  contaminen la comparación.

## 7.4 Métricas de evaluación

### 7.4.1 Métricas de rentabilidad-riesgo

Sobre la serie de 143 rentabilidades mensuales out-of-sample de cada cartera, se calculan:

- **Rentabilidad anualizada** (compuesta geométricamente):

$$r_{\text{anual}} = \left( \prod_{t=1}^T (1 + r_{p,t}) \right)^{12/T} - 1. \quad (7.1)$$

- **Volatilidad anualizada:**  $\sigma_{\text{anual}} = \sigma_{\text{mensual}} \cdot \sqrt{12}$ .
- **Ratio de Sharpe** (anualizado,  $r_f = 0$ ):  $S_p = r_{\text{anual}} / \sigma_{\text{anual}}$ .
- **Máximo drawdown:** máxima caída desde un pico anterior en la curva de valor acumulado. Expresado como:

$$\text{MDD} = \max_t \left( 1 - \frac{V_t}{\max_{s \leq t} V_s} \right), \quad (7.2)$$

donde  $V_t = \prod_{s=1}^t (1 + r_{p,s})$  es el valor acumulado de la cartera en el mes  $t$ .

#### 7.4.2 Métricas de composición de cartera

- **Turnover medio:** mide la rotación de la cartera entre rebalanceos consecutivos,

$$\text{TO} = \frac{1}{2(T-1)} \sum_{t=2}^T \sum_{i=1}^n |w_{i,t} - w_{i,t-1}|. \quad (7.3)$$

El factor  $1/2$  normaliza el turnover entre 0 (cartera estática) y 1 (rotación completa). Un turnover elevado implica mayores costes de transacción.

- **Índice Herfindahl-Hirschman (HHI) medio:**  $\text{HHI} = \frac{1}{T} \sum_t \sum_i w_{i,t}^2$ . Mide la concentración de la cartera:  $1/n$  para la equiponderada, 1 para un solo activo.
- **Número medio de activos en cartera:** media del número de activos con peso  $> 0,1\%$  en cada rebalanceo.

#### 7.4.3 Métricas de predicción ML

Para los modelos de ML se reportan además el RMSE, el MAE y el  $R^2$  out-of-sample de las predicciones de  $\mu$  (definidos en el Capítulo 6); un  $R^2$  negativo indica que el modelo predice peor que la media histórica, aunque la cartera podría aun así mejorar a la clásica si acierta el orden (ranking) de los activos.

### 7.5 Implementación y reproducibilidad

El código está implementado en Python 3.13 y organizado en módulos independientes bajo `src/`:

- `data_ingest/`: descarga y preprocesado de datos.
- `optimization/`: optimización QP (`cvxpy`), estimación de covarianza (`scikit-learn`) y restricciones.
- `ml/`: feature engineering, modelos (Ridge, Lasso, RF) y pipeline de predicción.
- `backtest/`: motor de backtesting walk-forward y métricas de evaluación.

La carpeta `tests/` valida la implementación (coincidencia del QP con la solución analítica y condiciones KKT, Capítulo 4), y `demo/` contiene una demostración web interactiva del optimizador, como apoyo a la presentación del trabajo.

La reproducibilidad está garantizada mediante una semilla fija (`seed = 42`) para todos los componentes aleatorios, las versiones de las dependencias congeladas

en `requirements.txt`, datos descargables automáticamente desde Yahoo Finance y scripts en `scripts/` que generan todas las tablas y figuras de la memoria.

## 7.6 Síntesis

El diseño experimental combina 6 carteras optimizadas (tres clásicas, una por estimador de  $\Sigma$ , y tres con  $\mu$  predicho por ML sobre Ledoit-Wolf) y 2 baselines pasivos, un backtesting walk-forward de 143 meses out-of-sample (ventanas de 36 meses, rebalanceo mensual) y métricas de rentabilidad-riesgo, composición y calidad predictiva. El Capítulo 8 presenta los resultados y el Capítulo 9, las conclusiones.

# 8

## Resultados y discusión


Este capítulo presenta y analiza los resultados del experimento descrito en el Capítulo 7. Se evalúan 6 carteras optimizadas (tres clásicas, una por estimador de  $\Sigma$ , y tres con  $\mu$  predicho por ML) y 2 baselines pasivos sobre 143 meses out-of-sample (enero 2013 – diciembre 2024).

### 8.1 Comparación global de carteras


La Tabla 8.1 presenta las métricas de todas las carteras evaluadas. La Figura 8.1 ordena las estrategias por ratio de Sharpe y la Figura 8.2 muestra la evolución del valor acumulado de 1€ invertido.

**Cuadro 8.1:** Resultados completos del backtesting walk-forward (enero 2013 – diciembre 2024, 143 meses).

| Estrategia              | Rent. anual ( % ) | Vol. anual ( % ) | Sharpe | Máx. DD ( % ) | Turnover | HHI  | Nº activos |
|-------------------------|-------------------|------------------|--------|---------------|----------|------|------------|
| Markowitz (muestral)    | 8,34              | 12,97            | 0,64   | 32,26         | 0,14     | 0,15 | 8,85       |
| Markowitz (Ledoit-Wolf) | 8,86              | 12,99            | 0,68   | 29,30         | 0,13     | 0,14 | 10,62      |
| Markowitz (PCA)         | 9,00              | 13,01            | 0,69   | 30,91         | 0,14     | 0,16 | 8,57       |
| Markowitz + Ridge       | 9,29              | 13,72            | 0,68   | 18,42         | 0,57     | 0,14 | 11,17      |
| Markowitz + Lasso       | 9,65              | 12,79            | 0,75   | 25,55         | 0,12     | 0,10 | 14,89      |
| Markowitz + RF          | 9,84              | 13,91            | 0,71   | 24,09         | 0,36     | 0,12 | 13,62      |
| 1/N (equiponderada)     | 10,68             | 14,14            | 0,76   | 21,89         | 0,00     | 0,03 | 30,00      |
| SPY (mercado)           | 12,94             | 14,42            | 0,90   | 25,48         | 0,00     | 1,00 | 1,00       |



**Figura 8.1:** Ratio de Sharpe anualizado por estrategia.



**Figura 8.2:** Evolución de 1€ invertido en cada estrategia durante el periodo out-of-sample (2013–2024). Las líneas discontinuas representan los baselines pasivos.

### 8.1.1 Resultado principal

El hallazgo más relevante es que **ninguna cartera optimizada supera a los baselines pasivos** en ratio de Sharpe. El SPY obtiene un Sharpe de 0,90 con una rentabilidad anualizada del 12,9 %, y la cartera 1/N equiponderada alcanza un Sharpe de 0,76 con un 10,7 % anualizado.

Entre las carteras optimizadas, la **Markowitz + Lasso** es la mejor, con un Sharpe de 0,75 y una rentabilidad del 9,7 % anualizado, hasta el punto de *igualar* en la práctica a la cartera 1/N (0,76). Le siguen **Markowitz + RF** (Sharpe 0,71) y **Markowitz (PCA)** (0,69). No obstante, como se demuestra en la Sección 8.5, ninguna de estas diferencias es estadísticamente significativa.

Este resultado es consistente con la literatura: DeMiguel, Garlappi y Uppal [DeMiguel et al., 2009](#) demostraron que se necesitan ventanas de estimación extremadamente largas (más de 3.000 meses) para que las carteras optimizadas superen consistentemente a la 1/N. Con 36 meses de ventana, el error de estimación domina cualquier ganancia teórica de la optimización.

### 8.1.2 Rentabilidad frente a riesgo

Todas las carteras optimizadas presentan volatilidades muy similares (12,8 %–13,9 % anual), cercanas a las de los baselines (14,1 %–14,4 %). La diferencia está en la rentabilidad: el SPY genera un 12,9 % frente al 8,3 %–9,8 % de las carteras optimizadas. Esto sugiere que el principal lastre de las carteras optimizadas no es un exceso de riesgo, sino una **rentabilidad sistemáticamente menor**: los activos que selecciona el optimizador rinden, fuera de muestra, menos que el mercado.

## 8.2 Efecto del estimador de covarianza

La Tabla 8.1 permite comparar el efecto de los tres estimadores de  $\Sigma$  cuando  $\mu$  se estima como media histórica.

El estimador **muestral** es el peor (Sharpe 0,64), con la mayor concentración (HHI 0,15; 8,9 activos). **Ledoit-Wolf** lo mejora en +0,04 (0,68), reduce la concentración (HHI 0,14; 10,6 activos) y baja el drawdown (29,3 % frente a 32,3 %). **PCA** logra el mejor Sharpe clásico (0,69), algo más rentable pero más concentrado (HHI 0,16; 8,6 activos).

Esto confirma el análisis del Capítulo 5: Ledoit-Wolf da las carteras más diversificadas y estables y el estimador muestral es el más vulnerable al error de estimación, con PCA en una posición intermedia —mejor rentabilidad, pero menor diversificación.

## 8.3 Efecto de la predicción ML de $\mu$

### 8.3.1 Rendimiento de las carteras ML

Las tres estrategias ML utilizan el estimador de covarianza Ledoit-Wolf y se diferencian únicamente en el modelo de predicción de  $\mu$ :

- **Lasso** (Sharpe 0,75) es la **mejor cartera optimizada** y prácticamente iguala a la  $1/N$ , con el menor turnover (0,12) y la mayor diversificación de las carteras optimizadas (14,9 activos, HHI 0,10).
- **Random Forest** (0,71), el único modelo no lineal, queda en segundo lugar, con un turnover moderado (0,36).
- **Ridge** (0,68) se queda en el Sharpe del clásico de Ledoit-Wolf, pero logra el **menor drawdown del estudio** (18,4 %).

### 8.3.2 Análisis del rendimiento de los modelos ML

El factor decisivo es el **tamaño efectivo de la muestra de entrenamiento**. Al estimar un único modelo agrupado sobre todos los activos (Capítulo 6), cada ajuste dispone de unas  $30 \times 36 \approx 1,000$  observaciones en lugar de 36. Por eso incluso Random Forest se comporta de forma estable (Sharpe 0,71): con solo 36 observaciones por activo un modelo no lineal sobreajustaría el ruido, pero con la muestra agrupada extrae una señal débil pero consistente.

Entre los lineales, Lasso supera a Ridge: la regularización  $\ell_1$  anula los coeficientes sin poder predictivo (selección automática) y, en un entorno de muy baja señal-ruido, produce predicciones parsimoniosas y estables —de ahí el bajísimo turnover de Lasso. De hecho, en muchos meses la validación cruzada elige un nivel que anula todos los coeficientes y reduce  $\hat{\mu}$  a una constante: cuando los datos no contienen señal aprovechable, el modelo lo refleja tal cual, en lugar de forzar una predicción ruidosa. Todo ello es coherente con la literatura [Gu et al., 2020](#), que subraya compartir información entre activos y regularizar con fuerza cuando los datos escasean.

### 8.3.3 Turnover y costes de transacción

La Tabla 8.1 muestra que el turnover varía notablemente: las estrategias con  $\mu$  histórico tienen un turnover de 0,13–0,14, frente al 0,12 de Lasso, el 0,36 de RF y el 0,57 de Ridge.

Frente al resultado habitual de que el ML dispara el turnover, aquí el modelo más parsimonioso (Lasso) alcanza uno incluso *inferior* al de las estrategias clásicas, mientras que Ridge —que mantiene activas todas las features— es el que más rota. Aun así, los costes de transacción siguen siendo relevantes para Ridge y RF: con un coste del 0,1 % por operación, el impacto anual aproximado ( $12 \times \text{turnover} \times 0,001$ ) restaría en torno a 0,4–0,7 puntos porcentuales de rentabilidad a esas dos estrategias, frente a apenas 0,1 en el caso de Lasso.



El matiz práctico es importante: **el coste de transacción no penaliza al ML en bloque, sino a los modelos cuyas predicciones de  $\mu$  son inestables mes a mes.**

## 8.4 Estabilidad temporal

La Figura 8.2 muestra que todas las estrategias optimizadas siguen trayectorias similares hasta aproximadamente 2018, cuando el SPY se despega, impulsado por el excepcional mercado estadounidense de 2019–2024 (recuperación post-COVID, auge de las grandes tecnológicas). Es notable que la  $1/N$ , con cero turnover y máxima diversificación, siga de cerca al SPY hasta 2020: refuerza que la diversificación ingenua es difícil de batir, sobre todo en mercados concentrados donde unas pocas acciones (Apple, Microsoft, NVIDIA) generan la mayor parte de la rentabilidad del índice.

## 8.5 Significación estadística

Comparar ratios de Sharpe con una única muestra de 143 meses sin medir su incertidumbre puede ser engañoso: una diferencia de centésimas puede deberse al ruido muestral. Para cuantificarlo se emplean dos herramientas complementarias (Tabla 8.2): un **intervalo de confianza al 95 %** del Sharpe por *bootstrap* de bloques —que preserva la autocorrelación— y el **test de Jobson-Korkie con la corrección de Memmel** Memmel, 2003, que contrasta si dos estrategias tienen el mismo Sharpe frente a cada baseline (SPY y  $1/N$ ).

**Cuadro 8.2:** Significación estadística de los ratios de Sharpe: intervalo de confianza al 95 % por *bootstrap* y *p*-valor del test de Memmel frente a cada baseline. El Sharpe de esta tabla se calcula como media/desviación típica mensual anualizada, ligeramente superior al de la Tabla 8.1 (geométrico) por el efecto del volatility drag.

| Estrategia              | Sharpe | IC 95 % inf. | IC 95 % sup. | <i>p</i> vs SPY | <i>p</i> vs $1/N$ |
|-------------------------|--------|--------------|--------------|-----------------|-------------------|
| Markowitz (muestral)    | 0,685  | 0,205        | 1,245        | 0,207           | 0,554             |
| Markowitz (Ledoit-Wolf) | 0,720  | 0,249        | 1,274        | 0,259           | 0,680             |
| Markowitz (PCA)         | 0,729  | 0,249        | 1,298        | 0,292           | 0,727             |
| Markowitz + Ridge       | 0,718  | 0,260        | 1,235        | 0,263           | 0,642             |
| Markowitz + Lasso       | 0,787  | 0,302        | 1,367        | 0,477           | 0,977             |
| Markowitz + RF          | 0,746  | 0,282        | 1,277        | 0,334           | 0,752             |
| $1/N$ (equiponderada)   | 0,792  | 0,305        | 1,358        | 0,206           | —                 |
| SPY (mercado)           | 0,921  | 0,399        | 1,559        | —               | 0,206             |

Los resultados son contundentes: **ninguna diferencia de Sharpe es estadísticamente significativa**. Todos los *p*-valores superan el 5 % —ninguno baja de 0,20—, e incluso comparar los dos baselines (SPY frente a  $1/N$ ) da  $p = 0,21$ ; los intervalos de confianza son además muy anchos (p. ej. [0,40, 1,56] para el SPY, [0,30, 1,37] para Lasso) y se solapan por completo. La lectura refuerza la tesis del trabajo: con 143 meses, **el error de estimación del propio Sharpe es tan grande que no permite afirmar que ninguna estrategia —ni siquiera el mercado— sea superior a las demás**. Las diferencias de la Tabla 8.1, aunque económicamente sugerentes, deben leerse con esta cautela.

## 8.6 Discusión crítica

### 8.6.1 ¿Por qué no se batan los baselines pasivos?

Los resultados muestran que, aunque la mejor estrategia con ML (Lasso) llega a igualar a la cartera  $1/N$ , ninguna estrategia —optimizada o pasiva— se distingue estadísticamente del resto, y todas quedan por debajo del SPY en términos puntuales. Varias razones lo explican:

1. **Señal débil:** la predictibilidad de las rentabilidades mensuales a partir de información de precio es muy limitada —los  $R^2$  de la literatura de *return prediction* rara vez superan el 2 % [Gu et al., 2020](#). El enfoque agrupado eleva el tamaño efectivo de entrenamiento a unas 1.000 observaciones y estabiliza los modelos, pero más datos no crean una señal inexistente: la regularización óptima descarta a menudo toda la señal.
2. **Inestabilidad de las predicciones:** en los modelos cuyas predicciones rotan mucho (Ridge y, menos, RF), los cambios en  $\hat{\mu}$  elevan el turnover y los costes implícitos.
3. **El QP amplifica el error:** el optimizador es muy sensible a los errores en  $\mu$  [Merton, 1980](#); una pequeña sobrestimación puede dar a un activo un peso desproporcionado.

### 8.6.2 Limitaciones del estudio

- **Sesgo de supervivencia:** solo constituyentes actuales del S&P 500, lo que sobrestima algo las rentabilidades del universo.
- **Sin costes de transacción explícitos:** el turnover se reporta pero no se descuenta, lo que favorece a las estrategias que más rotan.
- **Ventana única:** el periodo 2013–2024 fue excepcionalmente alcista en EE.UU.; los resultados podrían diferir en otros mercados.
- **Features y modelos limitados:** solo features de precio y tres modelos; variables fundamentales o arquitecturas más sofisticadas (gradient boosting, redes) podrían ayudar, a costa de más datos.

### 8.6.3 Implicaciones

Que ninguna estrategia optimizada se distinga estadísticamente de los baselines pasivos no debe leerse como un fracaso del enfoque, sino como una validación empírica de la dificultad fundamental de seleccionar carteras con parámetros estimados —la misma dificultad que justifica seguir investigando en estimadores robustos y métodos de predicción. Que Lasso sea la mejor cartera optimizada e iguale a la  $1/N$  —con bajo turnover y alta diversificación— sugiere que combinar un buen estimador de covarianza (Ledoit-Wolf) con una predicción regularizada y parsimoniosa es una dirección razonable; pero, a falta de significación estadística, esa mejora no puede darse por establecida con los datos disponibles, y confirmarla exigiría horizontes más largos, más activos o features adicionales.

# 9

## Conclusiones y líneas futuras

### 9.1 Conclusiones

Este trabajo ha abordado el problema de la optimización de carteras según el modelo de Markowitz, prestando especial atención a la estimación de sus dos parámetros fundamentales: la matriz de covarianza  $\Sigma$  y el vector de rentabilidades esperadas  $\mu$ . A continuación se sintetizan las principales conclusiones.

#### 9.1.1 Sobre la formulación matemática

El modelo de Markowitz es un programa cuadrático convexo (QP) de solución exacta cuyas condiciones KKT admiten una lectura económica clara: en el óptimo, el riesgo adicional que aporta cada activo es proporcional a su rentabilidad esperada. La excepción son los activos que chocan con una de las cotas de peso (quedarse en el 0 o en el tope del 20 %); para ellos, el precio sombra de esa cota mide cuánto bajaría el riesgo de la cartera si la cota pudiera relajarse. Sin restricciones de desigualdad, la frontera eficiente es una hipérbola en el plano  $(\sigma_p, \mu_p)$  cuyos parámetros dependen de tres escalares  $(A, B, C)$  que condensan la información de  $\mu$  y  $\Sigma$ .

#### 9.1.2 Sobre la estimación de la covarianza

La matriz de covarianza muestral, aunque insesgada, produce carteras excesivamente concentradas e inestables cuando el número de activos es comparable al de observaciones ( $n/T \approx 0,83$  en nuestro caso). Se han evaluado dos alternativas. El **shrinkage de Ledoit-Wolf** reduce el error cuadrático medio y da carteras más diversificadas y con mejor comportamiento out-of-sample (Sharpe 0,68 frente a 0,64 del muestral). El **estimador PCA**, que retiene los factores principales y conserva el riesgo específico de cada activo, obtiene el mejor Sharpe de las estrategias clásicas (0,69), aunque más concentrado.

La equivalencia entre el estimador PCA y el modelo factorial APT de Ross [Ross, 1976](#) constituye uno de los resultados metodológicos más relevantes del trabajo: los componentes principales de la matriz de covarianza son, bajo condiciones adecuadas, los factores de riesgo sistemático del mercado.

### 9.1.3 Sobre la predicción de $\mu$ con Machine Learning

Se ha implementado un sistema de predicción de  $\mu$  con tres modelos (Ridge, Lasso y Random Forest) entrenados de forma agrupada sobre los 30 activos, con 11 features derivadas exclusivamente de precios.

**Lasso** es el mejor modelo ML: su Sharpe de 0,75 iguala en la práctica a la  $1/N$ , con el menor turnover (la rotación de la cartera de un mes a otro; 0,12) y la mayor diversificación de las carteras optimizadas; la regularización  $\ell_1$  es especialmente valiosa en entornos de baja señal-ruido. **Random Forest** (0,71) y **Ridge** (0,68) son también competitivos; Ridge logra además el menor drawdown del estudio (18,4 %). Ninguna de estas diferencias, tampoco frente a los baselines, es estadísticamente significativa: con 143 meses, los intervalos de confianza del Sharpe son demasiado anchos para distinguir las estrategias.

La conclusión más relevante en este ámbito es que **la viabilidad del ML depende sobre todo de compartir información entre activos**: al estimar un único modelo agrupado (en torno a 1.000 observaciones, en lugar de 36 por activo), incluso un método no lineal como Random Forest se estabiliza y deja de sobreajustar.

### 9.1.4 Sobre la comparación con baselines pasivos

El resultado más honesto de este trabajo, y quizá el más valioso, es que **ninguna cartera optimizada supera de forma estadísticamente significativa a los baselines pasivos**: aunque Lasso iguala a la  $1/N$  (Sharpe 0,75 frente a 0,76) y todas quedan por debajo del SPY (0,90) en el valor puntual, los contrastes de Memmel no permiten rechazar que tengan el mismo Sharpe. Es coherente con la literatura [DeMiguel et al., 2009](#) y tiene una explicación clara: con 36 meses de ventana, el error de estimación de los 495 parámetros del modelo domina cualquier ganancia teórica de la optimización. La propia  $1/N$  lo ilustra: sin estimar ni optimizar nada, y con cero turnover, logra un 10,7 % anualizado con un 14,1 % de volatilidad.

### 9.1.5 Conclusión final

La integración de Machine Learning en el modelo de Markowitz produce carteras competitivas (la mejor, Lasso, iguala a la  $1/N$ ) cuando la predicción es agrupada y fuertemente regularizada, pero ninguna diferencia alcanza significación estadística: el error de estimación sigue siendo el factor limitante. Así, la principal contribución no es un modelo que gane al mercado, sino mostrar con rigor *por qué es tan difícil ganarle*: con datos realistas, las diferencias entre estrategias son indistinguibles del ruido. Y también qué técnicas ayudan a mitigar ese error de estimación, aunque no a eliminarlo.

## 9.2 Líneas futuras de investigación

Los resultados de este trabajo sugieren varias direcciones de investigación:

- **Ventanas de estimación más largas** (5–10 años), con un  $n/T$  más favorable, a costa de mezclar regímenes de mercado.

- **Más señal en  $\mu$ :** features fundamentales y macro (ratios contables, analistas, tipos, VIX) y técnicas de ML más potentes (Gradient Boosting, redes, LSTM), limitadas aquí por lo escaso de los datos (180 meses).
- **Tratar la incertidumbre de  $\mu$ :** optimización robusta (minimizar el peor caso en una región de confianza) o enfoques bayesianos como Black-Litterman.
- **Covarianza dinámica** (GARCH multivariante, EWMA) para correlaciones cambiantes en regímenes de estrés.
- **Gestión del turnover:** penalizarlo en la función objetivo o como restricción, para limitar los costes de transacción.
- **Validación en otros mercados** y clases de activos, para medir la generalidad de los resultados.

En definitiva, optimizar carteras con parámetros estimados (no conocidos) sigue siendo un problema abierto, en la frontera entre las matemáticas, la estadística y las finanzas. Este trabajo ha querido aportar a ese campo rigor matemático, honestidad empírica y una implementación reproducible.

# Bibliografía

Areia, José (dic. de 2023). *Polytechnic University of Leiria: LaTeX Thesis Template*. URL: <https://github.com/joseareia/ipleiria-thesis>.

Best, Michael J. y Robert R. Grauer (1991). «On the sensitivity of mean-variance-efficient portfolios to changes in asset means: some analytical and computational results». En: *The Review of Financial Studies* 4.2, págs. 315-342.

Black, Fischer y Robert Litterman (1992). «Global portfolio optimization». En: *Financial Analysts Journal* 48.5, págs. 28-43.

Boyd, Stephen y Lieven Vandenberghe (2004). *Convex Optimization*. Cambridge University Press.

Breiman, Leo (2001). «Random Forests». En: *Machine Learning* 45.1, págs. 5-32.

Cont, Rama (2001). «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues». En: *Quantitative Finance* 1.2, págs. 223-236.

DeMiguel, Victor, Lorenzo Garlappi y Raman Uppal (2009). «Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy?» En: *The Review of Financial Studies* 22.5, págs. 1915-1953.

Fama, Eugene F. y Kenneth R. French (1993). «Common risk factors in the returns on stocks and bonds». En: *Journal of Financial Economics* 33.1, págs. 3-56.

Gu, Shihao, Bryan Kelly y Dacheng Xiu (2020). «Empirical Asset Pricing via Machine Learning». En: *The Review of Financial Studies* 33.5, págs. 2223-2273.

Hoerl, Arthur E. y Robert W. Kennard (1970). «Ridge regression: biased estimation for nonorthogonal problems». En: *Technometrics* 12.1, págs. 55-67.

Jegadeesh, Narasimhan y Sheridan Titman (1993). «Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency». En: *The Journal of Finance* 48.1, págs. 65-91.

Jorion, Philippe (1986). «Bayes-Stein estimation for portfolio analysis». En: *Journal of Financial and Quantitative Analysis* 21.3, págs. 279-292.

Ledoit, Olivier y Michael Wolf (2004). «A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices». En: *Journal of Multivariate Analysis* 88.2, págs. 365-411.

Lintner, John (1965). «The Valuation of Risk Assets and the Selection of Risky Investments in Stock Portfolios and Capital Budgets». En: *The Review of Economics and Statistics* 47.1, págs. 13-37.

- Markowitz, Harry (1952). «Portfolio Selection». En: *The Journal of Finance* 7.1, págs. 77-91.
- Memmel, Christoph (2003). «Performance hypothesis testing with the Sharpe ratio». En: *Finance Letters* 1.1, págs. 21-23.
- Merton, Robert C. (1972). «An Analytic Derivation of the Efficient Portfolio Frontier». En: *The Journal of Financial and Quantitative Analysis* 7.4, págs. 1851-1872.
- Merton, Robert C. (1980). «On Estimating the Expected Return on the Market: An Exploratory Investigation». En: *Journal of Financial Economics* 8.4, págs. 323-361.
- Michaud, Richard O. (1989). «The Markowitz optimization enigma: is .°ptimized.°ptimal?» En: *Financial Analysts Journal* 45.1, págs. 31-42.
- Ross, Stephen A. (1976). «The Arbitrage Theory of Capital Asset Pricing». En: *Journal of Economic Theory* 13.3, págs. 341-360.
- Sharpe, William F. (1964). «Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk». En: *The Journal of Finance* 19.3, págs. 425-442.
- Sharpe, William F. (1966). «Mutual Fund Performance». En: *The Journal of Business* 39.1, págs. 119-138.
- Tibshirani, Robert (1996). «Regression shrinkage and selection via the lasso». En: *Journal of the Royal Statistical Society: Series B (Methodological)* 58.1, págs. 267-288.
- Tobin, James (1958). «Liquidity Preference as Behavior Towards Risk». En: *The Review of Economic Studies* 25.2, págs. 65-86.
- Zou, Hui y Trevor Hastie (2005). «Regularization and Variable Selection via the Elastic Net». En: *Journal of the Royal Statistical Society: Series B* 67.2, págs. 301-320.

# Apéndice





# Solución analítica de la frontera eficiente

Cuando se eliminan las restricciones de desigualdad ( $w_i \geq 0$  y  $w_i \leq w_{\max}$ ), el problema de Markowitz admite una solución analítica cerrada que constituye uno de los resultados clásicos de la teoría de carteras [Merton, 1972](#). Este apéndice recoge su derivación completa, a la que se remite desde el Capítulo 4. En todo el desarrollo se supone que  $\Sigma$  es **definida positiva** ( $\Sigma > 0$ ), hipótesis bajo la cual  $\Sigma^{-1}$  existe; en la práctica se cumple cuando el número de observaciones supera al de activos y ninguna combinación de activos es redundante (cuestión que se discute en el Capítulo 5).

## A.1 Caso sin restricciones de desigualdad

El problema se reduce a:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} \\ \text{s.a.} \quad & \mathbf{1}^T \mathbf{w} = 1, \\ & \mathbf{w}^T \boldsymbol{\mu} = \mu_p. \end{aligned} \tag{A.1}$$

Nótese que la restricción de rentabilidad se ha escrito como igualdad (=) en lugar de desigualdad ( $\geq$ ): en el óptimo, cualquier objetivo  $\mu_p$  alcanzable se saturará porque añadir rentabilidad sin aumentar riesgo es siempre beneficioso.

## A.2 Derivación mediante multiplicadores de Lagrange

El Lagrangiano del problema (A.1) es:

$$\mathcal{L}(\mathbf{w}, \lambda, \gamma) = \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} + \lambda(1 - \mathbf{1}^T \mathbf{w}) + \gamma(\mu_p - \mathbf{w}^T \boldsymbol{\mu}). \tag{A.2}$$

La condición de estacionariedad  $\nabla_{\mathbf{w}} \mathcal{L} = \mathbf{0}$  proporciona:

$$\Sigma \mathbf{w} - \lambda \mathbf{1} - \gamma \boldsymbol{\mu} = \mathbf{0} \implies \mathbf{w} = \Sigma^{-1}(\lambda \mathbf{1} + \gamma \boldsymbol{\mu}). \tag{A.3}$$

Sustituyendo en las restricciones  $\mathbf{1}^T \mathbf{w} = 1$  y  $\boldsymbol{\mu}^T \mathbf{w} = \mu_p$ , se obtiene un sistema

lineal  $2 \times 2$  para  $(\lambda, \gamma)$ :

$$\begin{pmatrix} A & B \\ B & C \end{pmatrix} \begin{pmatrix} \lambda \\ \gamma \end{pmatrix} = \begin{pmatrix} 1 \\ \mu_p \end{pmatrix}, \quad (\text{A.4})$$

donde se han definido las constantes escalares:

$$A = \mathbf{1}^T \Sigma^{-1} \mathbf{1}, \quad B = \mathbf{1}^T \Sigma^{-1} \boldsymbol{\mu}, \quad C = \boldsymbol{\mu}^T \Sigma^{-1} \boldsymbol{\mu}. \quad (\text{A.5})$$

Estas tres constantes dependen exclusivamente de  $\Sigma$  y  $\boldsymbol{\mu}$ ; no dependen del objetivo  $\mu_p$ . Como  $\Sigma > 0$ , también  $\Sigma^{-1} > 0$ , de modo que  $\langle \mathbf{x}, \mathbf{y} \rangle := \mathbf{x}^T \Sigma^{-1} \mathbf{y}$  define un producto interior. En esta métrica  $A = \langle \mathbf{1}, \mathbf{1} \rangle$ ,  $C = \langle \boldsymbol{\mu}, \boldsymbol{\mu} \rangle$  y  $B = \langle \mathbf{1}, \boldsymbol{\mu} \rangle$ , por lo que la desigualdad de Cauchy-Schwarz da  $B^2 \leq AC$ , con igualdad si y solo si  $\boldsymbol{\mu}$  y  $\mathbf{1}$  son linealmente dependientes (es decir, todos los activos tienen la misma rentabilidad esperada). Bajo la hipótesis de que  $\boldsymbol{\mu}$  y  $\mathbf{1}$  son linealmente independientes, se tiene  $\Delta = AC - B^2 > 0$ , lo que garantiza que la matriz del sistema (A.4) es invertible.

Resolviendo el sistema:

$$\lambda = \frac{C - B\mu_p}{\Delta}, \quad \gamma = \frac{A\mu_p - B}{\Delta}. \quad (\text{A.6})$$

### A.3 Ecuación de la frontera eficiente

Sustituyendo  $\lambda$  y  $\gamma$  en la expresión de la varianza  $\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w}$ , se obtiene la ecuación de la frontera eficiente en el espacio  $(\sigma_p, \mu_p)$ :

$$\sigma_p^2 = \frac{A\mu_p^2 - 2B\mu_p + C}{\Delta}. \quad (\text{A.7})$$

Esta ecuación describe una **hipérbola** en el plano  $(\sigma_p, \mu_p)$  —o una parábola en el plano  $(\sigma_p^2, \mu_p)$ —, cuya rama derecha ( $\sigma_p \geq 0$ ) es la **frontera de mínima varianza**: el lugar geométrico de las carteras de menor riesgo para cada nivel de rentabilidad. Su asíntota superior tiene pendiente  $\sqrt{\Delta/A}$ . La **frontera eficiente** propiamente dicha es solo la mitad superior de esa rama,  $\mu_p \geq \mu_{\text{GMV}} = B/A$  (el vértice que se deduce en la ecuación A.8): por debajo del vértice, toda cartera está dominada por otra de igual riesgo y mayor rentabilidad, y por tanto no es eficiente.

### A.4 Cartera de mínima varianza global (GMV)

El vértice de la hipérbola corresponde a la cartera de mínima varianza global. Derivando (A.7) respecto a  $\mu_p$  e igualando a cero:

$$\frac{d\sigma_p^2}{d\mu_p} = \frac{2A\mu_p - 2B}{\Delta} = 0 \implies \boxed{\mu_{\text{GMV}} = \frac{B}{A}}. \quad (\text{A.8})$$

Sustituyendo en (A.6) se obtiene  $\lambda = 1/A$ ,  $\gamma = 0$ , y el vector de pesos de la GMV es:

$$\boxed{\mathbf{w}_{\text{GMV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}}. \quad (\text{A.9})$$

La varianza de la GMV es  $\sigma_{\text{GMV}}^2 = 1/A$ .

### A.5 Cartera de máximo ratio de Sharpe

La cartera tangente (máximo ratio de Sharpe) se obtiene maximizando  $S_p = (\mu_p - r_f)/\sigma_p$  sobre la frontera. Con  $r_f = 0$ , la condición de optimalidad es:

$$\frac{\mu_p}{\sigma_p} = \frac{d\mu_p}{d\sigma_p} \implies \boxed{\mu_T = \frac{C}{B}, \quad \sigma_T^2 = \frac{C}{B^2}}. \quad (\text{A.10})$$

Y los pesos correspondientes:

$$\boxed{\mathbf{w}_T = \frac{\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}}{\mathbf{1}^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}}}. \quad (\text{A.11})$$

### A.6 Validación con la implementación numérica

La solución analítica (A.9) proporciona una referencia exacta contra la que verificar la implementación numérica con `cvxpy`. En el test `test_gmv_coincide_con_analitica_sin_restricciones` del código, se genera una matriz  $\boldsymbol{\Sigma}$  sintética (de  $3 \times 3$ ), se resuelve el QP sin restricciones de desigualdad y se comprueba que la solución numérica coincide con la expresión (A.9) con un error relativo inferior a  $10^{-5}$ . Este acuerdo valida tanto la formulación del QP como su resolución numérica.

# B

## Desarrollos matemáticos complementarios

Este apéndice recoge dos derivaciones autocontenidas a las que se remite desde el cuerpo del trabajo: la forma general de las condiciones de Karush-Kuhn-Tucker (Capítulo 4) y la construcción del estimador de covarianza por componentes principales junto con su equivalencia con el modelo APT (Capítulo 5).

### B.1 Condiciones de Karush-Kuhn-Tucker: planteamiento general

Consideremos el problema de optimización con restricciones de igualdad y desigualdad:

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{s.a.} \quad & g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m, \\ & h_j(\mathbf{x}) = 0, \quad j = 1, \dots, p. \end{aligned} \tag{B.1}$$

El **Lagrangiano** asociado es:

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i g_i(\mathbf{x}) + \sum_{j=1}^p \nu_j h_j(\mathbf{x}), \tag{B.2}$$

donde  $\lambda_i \geq 0$  son los multiplicadores de las restricciones de desigualdad y  $\nu_j \in \mathbb{R}$  los de las igualdades. En el Capítulo 4 este planteamiento se particulariza al programa cuadrático de Markowitz.

### B.2 Lagrangiano del QP de Markowitz

Escribiendo el QP (4.1) en la forma estándar anterior, la función objetivo es  $f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w}$  y las restricciones de desigualdad  $g_i(\mathbf{w}) \leq 0$  son:

$$g_i^{(1)}(\mathbf{w}) = -w_i \leq 0, \quad i = 1, \dots, n, \quad (\text{long-only}), \tag{B.3}$$

$$g_i^{(2)}(\mathbf{w}) = w_i - w_{\max} \leq 0, \quad i = 1, \dots, n, \quad (\text{tope por activo}), \tag{B.4}$$

$$g^{(3)}(\mathbf{w}) = \mu^* - \mathbf{w}^T \boldsymbol{\mu} \leq 0, \quad (\text{rentabilidad objetivo}), \tag{B.5}$$

junto con la restricción de igualdad

$$h(\mathbf{w}) = \mathbf{1}^T \mathbf{w} - 1 = 0. \quad (\text{B.6})$$

Introduciendo los multiplicadores  $\alpha_i \geq 0$  (cota inferior),  $\beta_i \geq 0$  (cota superior),  $\gamma \geq 0$  (rentabilidad objetivo) y  $\lambda \in \mathbb{R}$  (presupuesto), el Lagrangiano es:

$$\begin{aligned} \mathcal{L}(\mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta}, \gamma, \lambda) = & \frac{1}{2} \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w} - \sum_{i=1}^n \alpha_i w_i + \sum_{i=1}^n \beta_i (w_i - w_{\max}) \\ & + \gamma (\mu^* - \mathbf{w}^T \boldsymbol{\mu}) + \lambda (1 - \mathbf{1}^T \mathbf{w}). \end{aligned} \quad (\text{B.7})$$

Las condiciones KKT que de aquí se derivan se enuncian e interpretan en el Capítulo 4.

### B.3 Estimador de covarianza por PCA y equivalencia con la APT

La matriz de covarianza muestral admite una descomposición espectral:

$$\boldsymbol{\Sigma} = \mathbf{V} \boldsymbol{\Lambda} \mathbf{V}^T = \sum_{i=1}^n \lambda_i \mathbf{v}_i \mathbf{v}_i^T, \quad (\text{B.8})$$

donde  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$  son los autovalores (ordenados de mayor a menor) y  $\mathbf{v}_1, \dots, \mathbf{v}_n$  los autovectores. Cada autovalor  $\lambda_i$  representa la varianza explicada por el  $i$ -ésimo componente principal. El estimador PCA retiene únicamente los  $k$  primeros componentes (los factores principales) y descarta los  $n - k$  restantes, que se atribuyen a ruido:

$$\boldsymbol{\Sigma}_k = \sum_{i=1}^k \lambda_i \mathbf{v}_i \mathbf{v}_i^T, \quad (\text{B.9})$$

y conserva la varianza específica de cada activo no explicada por los factores comunes (la diagonal del residuo):

$$\boldsymbol{\Sigma}_{\text{PCA}} = \boldsymbol{\Sigma}_k + \text{diag}(\boldsymbol{\Sigma} - \boldsymbol{\Sigma}_k). \quad (\text{B.10})$$

La Arbitrage Pricing Theory de Ross [Ross, 1976](#) postula que las rentabilidades se generan por un modelo factorial:

$$r_i = \alpha_i + \sum_{j=1}^k \beta_{ij} f_j + \varepsilon_i, \quad (\text{B.11})$$

donde  $f_1, \dots, f_k$  son factores de riesgo sistemático y  $\varepsilon_i$  es el riesgo idiosincrásico del activo  $i$ , no correlacionado con los factores ni con los  $\varepsilon$  de otros activos. Bajo este modelo, la covarianza se descompone como

$$\boldsymbol{\Sigma} = \mathbf{B} \boldsymbol{\Sigma}_f \mathbf{B}^T + \boldsymbol{\Psi}, \quad (\text{B.12})$$

con  $\mathbf{B}$  la matriz de cargas factoriales  $(\beta_{ij})$ ,  $\boldsymbol{\Sigma}_f$  la covarianza de los factores y  $\boldsymbol{\Psi}$  una matriz diagonal con las varianzas idiosincrásicas. Si se toman como factores los  $k$  primeros componentes principales de las rentabilidades, el estimador (B.10) es exactamente el estimador APT: las cargas vienen dadas por  $\mathbf{B} = \mathbf{V}_k \boldsymbol{\Lambda}_k^{1/2}$  y la covarianza de los factores es  $\boldsymbol{\Sigma}_f = \mathbf{I}_k$  (por ortogonalidad de los componentes principales). Esta equivalencia conecta el enfoque puramente estadístico (PCA) con la teoría financiera (APT).

